

S&P 500: ein Umwelt-Ranking, das seine eigenen Grenzen misst

Fusionsbericht — beide Ansätze zusammengeführt, alle Kritikpunkte abgearbeitet
ETHack 2026, Challenge #1

12. September 2026

Worum es geht. Zwei unabhängige Pipelines haben dieselbe Challenge bearbeitet und kamen bei den Kernbefunden überein — das ist das stärkste Validitätssignal der ganzen Übung. Beide hatten aber auch Schwachstellen, die der jeweils andere aufdeckte. Dieser Bericht führt beide zusammen und arbeitet siebzehn benannte Kritikpunkte ab. Drei Ergebnisse sind unbequem: Der Faktor-3-Fehler bei den Rohdaten ist real und war fast im Ergebnis. Nach der Entkorrelierung der Kennzahlen wird das Rangband *breiter*, nicht schmäler — die vorherige Enge war teilweise ein Artefakt redundanter Indikatoren. Und die Größenverzerrung, die beide Vorberichte für unbedenklich hielten, ist nach der Umstellung auf Intensität statistisch signifikant.

Zum Titel. Dieser Bericht hieß in früheren Fassungen „Nachhaltigkeits-Ranking“. Das war nicht gedeckt: Alle Kennzahlen waren Blickwinkel auf CO₂. Inzwischen kommen zwei weitere Datenquellen dazu (Giftstofffreisetzung, Arbeitsunfälle), aber Governance fehlt weiterhin ganz. „Umwelt-Ranking“ ist die ehrliche Bezeichnung — siehe Abschnitt 10.

Inhalt

1	Was sich geändert hat	3
2	Stufe 1: Die Daten, und ein Fehler mit Faktor drei	3
2.1	Direktemission, Lieferant, Injektion	3
2.2	Eine harte Validierung	4
2.3	Zuordnung: vier Schwellen statt einer	4
3	Stufe 2: Kennzahlen, die sich nicht gegenseitig erzählen	5
3.1	Das Problem	5
3.2	Der Umbau	5
3.3	Was mit der Messqualität passiert ist	6
3.4	Vergleichsgruppen aus den Daten	6
4	Stufe 3: 768 Konfigurationen	6
5	Ergebnis 1: Zwei Listen, nicht eine	7
6	Ergebnis 2: Das Band, und ein unbequemer Befund	8
7	Ergebnis 3: Haben die Korrekturen gewirkt?	8
7.1	Geometrisch gegen additiv	9
7.2	Imputation	9
7.3	Vintage: was eine Fortschreibung kostet	9

7.4	Groessenverzerrung — ein neues Problem	9
8	Ergebnis 4: Achse B, vier Signale	10
9	Ergebnis 5: Das Netto-null-Portfolio	10
10	Mehr als CO₂: was drei neue Quellen bringen	11
10.1	EPA TRI: Giftstofffreisetzung	11
10.2	OSHA: Arbeitsunfaelle	11
10.3	EIA-923: der physische Nenner, der nicht kam	12
10.4	Was damit erreicht ist — und was nicht	12
11	Was weiterhin nicht geloest ist	12
11.1	Was als Naechstes den groessten Unterschied macht	13
12	Reproduktion	14

1 Was sich geändert hat

Die folgende Tabelle ist der Kern dieses Berichts. Jede Zeile ist ein Kritikpunkt aus der Zweitbewertung, die jeweilige Gegenmaßnahme und das gemessene Ergebnis danach.

	Kritikpunkt	Gegenmaßnahme	Gemessenes Ergebnis
K1	Nur ein von sechs Direktemittenten-Blättern gelesen	Alle sechs geladen, Lieferanten und Injektion ausdrücklich ausgeschlossen	2 578,6 Mt — trifft die veröffentlichte EPA-Zahl exakt
K2	Doppelzählung durch Lieferantenzeilen nicht geprüft	E/S/I-Audit als Pflichtschritt	Naive Summe wäre Faktor 3,19 zu hoch
K3	Matching-Schwelle willkürlich gesetzt	Vier Schwellen (85/90/92/95) als Datenvariante	Effekt gemessen: nur 0,002 der Streuung
K4	Zurechnungsregel versteckt im Code	Equity-Share und operative Kontrolle als Achse	Effekt gemessen: 0,014 der Streuung
K5	Kennzahlen korreliert, Geometrie wirkungslos	Trendpaar ersetzt durch Trendabweichung + Momentum	Aggregationswahl verschiebt jetzt 7,7 pp statt 0
K6	GICS ist die falsche Vergleichsgruppe	k-Means über NAICS-Emissionsprofile, Mindestgröße 8	Berkshire liegt jetzt bei 29 Versorgern statt bei Banken
K7	Messqualität nicht erfasst	CEMS-Anteil aus dem EPA-Feld Unit Reporting Method	Korreliert 0,65 mit Kohle — deshalb auf Achse B
K8	Vintage nicht geprüft	Rückwärtstest: alte Emissionen, neue Umsätze	$\rho = 0,98$; 9,3 % verschieben sich über 10 pp
K9	Imputation als unkritisch behauptet	Auslass-Test ohne die betroffenen Firmen	Reihenfolge unverändert ($\rho = 1,000$)
K10	Größenverzerrung ungeprüft	Rangkorrelation Umsatz gegen Perzentil	$\rho = 0,432$, signifikant — neues Problem
K11	Eine Liste behauptet, die es nicht gibt	Zwei Listen: bewertbar und nicht bewertbar mit Grund	116 bewertbar, 387 nicht
K12	Greenwashing nur teilweise erfasst	Vier Signale statt einem	49 Firmen mit steigendem Ausstoß, 43 mit bequemem Basisjahr
K13	Portfolio auf absoluten Tonnen	PAB auf Emissionsintensität	387,7 → 193,8 t je Mio. USD

2 Stufe 1: Die Daten, und ein Fehler mit Faktor drei

2.1 Direktemission, Lieferant, Injektion

Die EPA-Tabelle enthält drei Arten von Meldern, und sie lassen sich nicht addieren:

- **Direktemission (E)**. Was eine Anlage selbst ausstoßt. Das ist Scope 1.
- **Lieferant (S)**. Der Kohlenstoff in verkauften Kraftstoffen, der später beim Kunden freigesetzt wird.
- **Injektion (I)**. Eingelagertes, also gerade nicht ausgestoßenes CO₂.




Figure 1: Wer die Lieferantenzeilen mitzählt, rechnet einem Ölkonzern die Emissionen seiner Kunden als eigene an — und zählt dieselbe Tonne ein zweites Mal bei dem Kraftwerk, das den Kraftstoff verbrennt.

Der Fehler hätte plausibel ausgesehen. Ein Ranking auf der naiven Summe hätte die Raffineriebetreiber ans Ende jeder Liste gesetzt. Genau deshalb ist dieser Schritt keine Feinheit: Das GHG-Protokoll untersagt diese Doppelzählung ausdrücklich, und das Ergebnis wäre um den Faktor 3,19 daneben — ohne dass es jemandem auffällt.

2.2 Eine harte Validierung

Nach dem Einlesen aller sechs Direktemittenten-Blätter ergeben sich für 2023 **2 578,6 Mio. t CO₂e**. Die EPA veröffentlicht für dasselbe Berichtsjahr 2,58 Mrd. t. Das ist keine Plausibilität, sondern eine Punktlandung — und die einzige echte externe Prüfung der Datenaufbereitung, die ohne gekaufte Daten möglich ist.

Grundlage sind 100 347 Anlage-Jahr-Zeilen aus 10 518 Anlagen, 2011–2023.

2.3 Zuordnung: vier Schwellen statt einer

Die EPA kennt Anlagen und Konzernnamen als Freitext, keine Ticker. Jede Zuordnung ist eine Entscheidung mit Fehlerrisiko. Statt eine Schwelle zu wählen und zu hoffen, rechnen wir alle vier:

Schwelle	zugeordnete Namen	getroffene Firmen	Mt 2023 (Equity)
85	393	147	1 084
90	353	140	1 071
92	347	140	1 060
95	330	139	1 060

Dazu zwei Zurechnungsregeln: *Equity-Share* rechnet einer Firma ihren Eigentumsanteil zu, *operative Kontrolle* gibt dem größten Eigentümer 100 Prozent. Bei einer 50/50-Anlage unterscheiden sich die Ergebnisse um den Faktor zwei.

Zusammen ergibt das **acht Datenvarianten**. Sie sind keine Sensitivitätsspielerei, sondern die Stelle, an der bisher versteckte Ermessensentscheidungen messbar werden.

3 Stufe 2: Kennzahlen, die sich nicht gegenseitig erzählen

3.1 Das Problem

Der Vorgängerbericht hatte zwei Trendkennzahlen, die mit $\rho = 0,64$ korrelierten, weil sie aus derselben Emissionsreihe stammten. Die Folge: Die multiplikative Aggregation — methodisch das Herzstück — veränderte im Median gar nichts. Nicht-Kompensierbarkeit kann nur dort greifen, wo es etwas zu kompensieren gibt.

3.2 Der Umbau

Indikator	Was er misst	Fehlerbalken
log_intensity	Emissionen je Mio. USD Umsatz	Fehlerfortpflanzung aus Zähler und Nenner
trend_rel	Langtrend <i>minus Gruppenmedian</i> : sinkt die Firma schneller als ihre direkte Konkurrenz?	Standardfehler der Regressionssteigung
momentum	Kurztrend minus Langtrend: beschleunigt sie?	Fehlerfortpflanzung aus beiden
coal_share	Kohleanteil der fossilen Verbrennung	Binomialfehler über die Brennstoffzeilen
asset_hhi	Hängen die Emissionen an wenigen Anlagen?	Streuung über die Anlagen
volatility	Reststreuung der log-Emissionen	Freiheitsgrade der Regression

Die entscheidende Änderung ist `trend_rel`: Statt des absoluten Trends zählt die Abweichung vom Gruppenmedian. Damit ist die Kennzahl unabhängig vom Niveau — und genau darum ging es.




Figure 2: Nach dem Umbau liegt die größte Korrelation bei $|\rho| = 0,57$ (Kohleanteil gegen Intensität, sachlich unvermeidbar), der Median bei 0,20.

3.3 Was mit der Messqualitaet passiert ist

Das EPA-Feld Unit Reporting Method unterscheidet berechnete (Tier 1–3) von kontinuierlich gemessenen Emissionen (Tier 4 / CEMS). Der Anteil gemessener Emissionen lag nahe, als siebter Indikator.

Die Korrelationsprüfung hat das verhindert: $\rho = 0,65$ zum Kohleanteil, $\rho = 0,62$ zur Intensität. Der CEMS-Anteil misst im Wesentlichen „betreibt diese Firma Kohlekraftwerke“ — und wäre als Score-Indikator eine dritte Stimme für dieselbe Aussage gewesen. Er steht deshalb auf Achse B, wo er hingehört: als Aussage über Berichtsqualität, nicht über Nachhaltigkeit.

3.4 Vergleichsgruppen aus den Daten

GICS sortiert Firmen nach Umsatzquellen, nicht nach Emissionsprofil. Berkshire Hathaway steht mit über 50 Mio. t unter *Financials* und wird gegen Banken verglichen — ein Ergebnis, das nichts über die Firma sagt, nur über die Taxonomie.

Die Gegenmaßnahme: k-Means über das NAICS-Emissionsprofil jeder Firma, mit erzwungener Mindestgröße von acht.

Der Test. Berkshire Hathaway landet in Profilgruppe P2 — gemeinsam mit 29 Versorgern und einem zweiten Finanztitel (Ares Management, ebenfalls mit Kraftwerksbeteiligungen). Die Gruppe wurde nie mit dieser Absicht gebaut; sie ergibt sich aus den Anlagendaten. Das ist die sauberste Bestätigung, dass der Fix greift.

Sechs Profilgruppen mit Größen von 8 bis 38. GICS bleibt als zweite Sicht erhalten — und beide Schemata sind eine Achse im Kombinationsraum, sodass ihr Einfluss gemessen wird statt behauptet.

4 Stufe 3: 768 Konfigurationen

Dimension	Stufen	Auspraegungen
Normalisierung	3	Rang, gestutzter Z-Wert, Min-Max
Gewichtung	4	Gleich, Entropie, Hauptkomponenten, Experten
Aggregation	2	Addition, Multiplikation
Gruppenschema	2	Emissionsprofil (k-Means), GICS
Lückenfüllung	2	Gruppenmedian, Gesamtmedian
Zurechnung	2	Equity-Share, operative Kontrolle
Matching-Schwelle	4	85, 90, 92, 95
Konfigurationen		96 Methoden $\times$ 8 Datenvarianten = 768
Ziehungen		100 je Konfiguration, identische Zufallszahlen
Ergebnis		76 800 Ranglisten, 8,9 Mio. Perzentilwerte

Weil jede Konfiguration dieselben 100 Ziehungen sieht, ist das Design voll faktoriell — und die Varianzzerlegung exakt berechenbar statt geschätzt.




Figure 3: Haupteffekt (kräftig) und Totaleffekt inklusive Wechselwirkungen (hell). Grün sind Datenvarianten, blau Methodenentscheidungen.

Faktor	Haupteffekt	Totaleffekt	Art
Verteilungsziehung	0,182	0,418	Daten
Gewichtung	0,136	0,301	Methode
Gruppenschema	0,102	0,230	Methode
Normalisierung	0,079	0,292	Methode
Aggregation	0,069	0,178	Methode
Lückenfüllung	0,053	0,115	Methode
Zurechnung	0,013	0,045	Daten
Matching-Schwelle	0,003	0,011	Daten
Summe Haupteffekte		0,637	
Wechselwirkungen		0,363	

Drei Lesarten.

Erstens: Zurechnung und Matching sind fast egal. Zusammen 0,016. Das ist ein wertvolles Ergebnis, weil beides vorher als großes Risiko galt. Es ist jetzt gemessen statt vermutet — und wer eine Diskussion über die Matching-Schwelle führt, diskutiert den kleinsten Hebel überhaupt.

Zweitens: Die Gewichtung ist nach vorn gerückt. Im Vorgängermodell lag sie bei 0,090, jetzt bei 0,136 — der zweitgrößte Methodeneffekt. Das ist die direkte Folge der Entkorrelierung: Wenn Kennzahlen dasselbe sagen, ist ihre Gewichtung gleichgültig. Erst unabhängige Dimensionen machen Gewichte wirksam.

Drittens: 36 Prozent stecken in Wechselwirkungen. Die Faktoren wirken nicht unabhängig. Welche Normalisierung passt, hängt vom Gruppenschema ab. Deshalb reicht es nicht, Entscheidungen einzeln durchzuprobieren — man braucht das volle Kreuzprodukt.

5 Ergebnis 1: Zwei Listen, nicht eine

116 der 503 Firmen sind bewertbar, 387 nicht. Entscheidend ist nicht die Zahl, sondern das Muster: Versorger 93,5 Prozent, Immobilien 3,3 Prozent.




Figure 4: Anteil der Indexmitglieder je GICS-Sektor mit verwertbaren Emissionsdaten.

Die wichtigste Einschränkung des ganzen Modells. Die 116 bewertbaren Firmen sind keine Stichprobe des S&P 500, sondern seine Schwerindustrie. Wer bei Microsoft, JPMorgan oder Visa nach Emissionen sucht, findet fast nichts — nicht weil diese Firmen sauber wären, sondern weil ihr Fußabdruck in Scope 2 und Scope 3 liegt, wo es keine freien Daten gibt. Das Ranking beantwortet damit nicht „wer ist nachhaltig“, sondern „wer betreibt große Schornsteine, und wie effizient“. Deshalb gibt es zwei Listen und für jede nicht bewertbare Firma eine Begründung — keine stille Auslassung.

6 Ergebnis 2: Das Band, und ein unbequemer Befund

Das mediane Band ist **52,9 Perzentilpunkte** breit. Bei einer mittleren Gruppengröße entspricht das rund **13 Rangplätzen**. Nur 2 von 116 Firmen sind nach strenger Definition robust platziert. Legt man sich auf ein Gruppenschema fest, sinkt es auf 46,7 Punkte — kaum besser.

Das Band ist nach den Korrekturen breiter geworden, nicht schmaler. Der Vorgängerbericht meldete innerhalb des Sektors sieben Rangplätze. Jetzt sind es zwölf bis dreizehn. Die Ursache ist nicht schlechtere Arbeit, sondern die Entkorrelierung: Solange zwei von sechs Kennzahlen dasselbe sagten, waren Gewichtung und Aggregation weitgehend wirkungslos, und das Ergebnis wirkte stabiler, als es war. Die alte Enge war zu einem Teil ein Artefakt redundanter Indikatoren. Das ist die unangenehmste Erkenntnis dieses Berichts — und der Grund, warum eine Unsicherheitsanalyse nur dann etwas wert ist, wenn sie auch das eigene Modell prüfen darf.

Was trotzdem trägt: Aussagen auf Tertil-Ebene. Statt „Platz 4 von 31“ hält „liegt in 88 Prozent aller Konfigurationen im oberen Drittel ihrer Profilgruppe“. Diese Formulierung steht in der Ausgabe, die Einzelplatzierung nicht.

7 Ergebnis 3: Haben die Korrekturen gewirkt?

Vier Tests, jeder mit einer Zahl statt einer Behauptung.

7.1 Geometrisch gegen additiv

Der Vorgänger maß eine mediane Abweichung von **exakt null** Perzentilpunkten zwischen beiden Aggregationsverfahren; nur 8,9 Prozent der Firmen verschoben sich um mehr als zehn Punkte. Mit den entkorrelierten Kennzahlen:

	vorher (korrelierte Kennzahlen)	jetzt
mediane Abweichung	0,0 pp	7,7 pp
Anteil über 10 pp	8,9 %	41,4 %
größte Abweichung	69 pp	36,5 pp

Der Fix greift. Die Entscheidung zwischen Addition und Multiplikation — also die Frage, ob eine Bestnote eine katastrophale Note zurückkaufen darf — verändert jetzt bei fast der Hälfte der Firmen die Einordnung spürbar. Vorher war sie folgenlos. Die multiplikative Aggregation bleibt die Voreinstellung, und sie ist jetzt eine scharfe Klinge statt einer Zierde.

7.2 Imputation

27 der 116 Firmen haben keinen echten Umsatzwert und bekommen den Gruppenmedian mit stark aufgeblähtem Fehlerbalken. Der Vorwurf lautete, der kleine ANOVA-Effekt belege nur gutes Handling, nicht Harmlosigkeit.

Der direkte Test: die Rangfolge der übrigen 89 Firmen einmal mit und einmal ohne die imputierten Firmen. Ergebnis: $\rho = 1,000$, die Reihenfolge ist identisch; die Perzentilwerte verschieben sich im Median um 4,5 Punkte, weil die Grundgesamtheit kleiner wird.

Das entlastet nur teilweise. Der Test zeigt, dass die imputierten Firmen die *anderen* nicht verzerren. Er sagt nichts darüber, ob die 27 Firmen selbst richtig eingeordnet sind. Das ließe sich nur durch Nachtragen der fehlenden Umsätze klären — Aufwand: eine ergänzte CSV-Datei.

7.3 Vintage: was eine Fortschreibung kostet

Ab Geschäftsjahr 2024 gibt es keine freien Emissionsdaten mehr. Die praktische Frage ist nicht, ob das ideal ist, sondern was eine Fortschreibung kostet. Messbar wird das rückwärts: Emissionen aus 2021 mit Umsätzen von heute kombinieren und gegen die echte Rangliste halten.

Rangkorrelation zur echten Rangliste	$\rho = 0,98$
Median-Abweichung	0,0 Perzentilpunkte
90. Perzentil der Abweichung	6,5 Perzentilpunkte
Anteil über 10 Punkte Abweichung	9,3 %

Das fällt günstiger aus als im Vergleichsbericht ($\rho = 0,84$). Der Grund ist methodisch und gehört dazugesagt: Hier variiert *nur* der Emissionsjahrgang, der Umsatz bleibt fest — das ist exakt das Fortschreibungsszenario, aber eben auch der günstigste Fall. Zudem sind die Profilgruppen größer, was Rangsprünge dämpft.

Praktische Folge: Eine Fortschreibung ist vertretbar, wenn das Band um den gemessenen Fehler aufgeweitet und das Datenalter je Firma angezeigt wird. Ohne beides nicht.

7.4 Groessenverzerrung — ein neues Problem

Beide Vorberichte fanden keinen Zusammenhang zwischen Firmengröße und Bewertung ($\rho = 0,12$ und $0,11$, beide nicht signifikant). Nach der Umstellung auf Emissionsintensität sieht das anders

aus:

Rangkorrelation Umsatz gegen Score-Perzentil	$\rho = 0,432$
p-Wert	$< 0,01$
Stichprobe	89 Firmen mit echtem Umsatz

Große Firmen schneiden systematisch besser ab — und der Grund ist mechanisch. Die Intensität hat den Umsatz im Nenner. Wer denselben Ausstoß auf mehr Umsatz verteilt, sieht effizienter aus, ohne eine Tonne weniger auszustoßen. Das ist nicht die aus der Literatur bekannte Offenlegungs-Verzerrung, sondern ein Nenner-Effekt des eigenen Modells. Er ist erst sichtbar geworden, weil der Test überhaupt gelaufen ist. Er ist *nicht* behoben. Gegenmaßnahme für die nächste Iteration: physische Nenner je Gruppe (Megawattstunden, Tonnen Stahl, Tonnen Zement) statt Umsatz — die NAICS-Profile liegen bereits vor.

8 Ergebnis 4: Achse B, vier Signale

Glaubwürdigkeit gehört nicht in den Score. Eine Firma kann sauber wirtschaften und unglaublich unwürdig berichten — das sind zwei verschiedene Informationen, und wer sie verrechnet, zerstört beide.

Signal	Firmen	Woran es erkannt wird
Kaum gemessene Emissionen	83	CEMS-Anteil unter 20 Prozent
Kein SBTi-Ziel	75	nicht im Target Dashboard
Absoluter Ausstoß steigt	49	positiver Trend der absoluten Tonnen
Bequemes Basisjahr	43	erstes Jahr über 110 Prozent des Reihenmedians
Hinter dem eigenen Ziel	20 von 26	realisierte Rate schlechter als SBTi-Ziel

Der letzte Punkt bleibt der schärfste. Aus dem SBTi-Zieltext („reduce absolute scope 1 and 2 GHG emissions 42% by 2030 from a 2019 base year“) wird die geforderte Jahresrate $\ln(1 - 0,42)/11 = -4,95\%$ gezogen und gegen die tatsächlich erreichte Rate aus 13 Jahren Behördendaten gestellt. 20 von 26 Firmen mit auswertbarem Ziel liegen dahinter; Median gefordert $-6,3\%$, Median erreicht $-1,0\%$.

Die Ziellücke vergleicht Ungleiches. Das SBTi-Ziel deckt meist Scope 1 und 2 bis 2030 ab, unsere Messung nur Scope 1 von 2011 bis 2023. Die Richtung ist belastbar, die Zahl je Firma nicht. Zwei der sechs bekannten Warnsignale fehlen weiterhin ganz: Scope-3-Abdeckung und widersprüchliche Lobbyarbeit.

9 Ergebnis 5: Das Netto-null-Portfolio

Die Bonusfrage: eine Milliarde Dollar unter einem sofortigen globalen Netto-null-Ziel. Die EU hat dafür eine fertige Regel, den *Paris-Aligned Benchmark*: mindestens 50 Prozent weniger CO₂-Intensität als der Vergleichsindex, danach 7 Prozent pro Jahr — und klimaintensive Branchen dürfen dabei **nicht untergewichtet** werden. Nur so entsteht Wettbewerbsdruck innerhalb der Branche, statt das Problem an andere Eigentümer weiterzureichen.

Der Vorgänger optimierte auf absolute Tonnen, weil Umsatzdaten fehlten. Das ist jetzt behoben.

Benchmark-Intensität	387,7 t CO ₂ e je Mio. USD Umsatz
Portfolio-Intensität	193,8
Reduktion	–50,0 % (PAB-Schwelle erfüllt)
Sektoren untergewichtet	keiner
Gewichtsabweichung zum Benchmark	0,0458
Titel im Portfolio	87 von 89
Größtes Einzelgewicht	2,54 %

Das Portfolio halbiert die Intensität, ohne eine einzige Branche zu verlassen und ohne sich stark vom Vergleichsindex zu entfernen. Genau das ist die Aussage von Andersson, Bolton & Samama (2016): Die Absicherung gegen Klimaregulierung gibt es faktisch geschenkt.

10 Mehr als CO₂: was drei neue Quellen bringen

Bis hierher war jede Kennzahl ein Blick auf dieselbe Emissionsreihe. Damit konnte die multiplikative Aggregation nur zwischen Varianten desselben Themas unterscheiden — und der Titel „Nachhaltigkeit“ war schlicht nicht gedeckt. Drei Quellen wurden geprüft.

10.1 EPA TRI: Giftstofffreisetzung

Der nationale Datensatz 2023 enthält 78 648 Meldezeilen mit Luft-, Wasser- und Bodenfreisetzungen je Chemikalie, dazu ein Krebserreger-Merkmal und das Feld STANDARD PARENT CO NAME. Über dieselbe Namenszuordnung wie beim GHGRP ergeben sich 14 825 Zeilen für 183 S&P-Firmen, zusammen rund 250 000 t freigesetzte Stoffe.

Die Korrelationsprüfung entschied dann gegen die naheliegende Kennzahl:

Kandidat	$ \rho $ zur CO ₂ -Intensität	Entscheidung
Giftstoffe je Umsatz	0,71	verworfen
Anteil krebserregender Stoffe	0,01	in den Score

Die Freisetzungsmenge je Umsatz misst weitgehend dasselbe wie CO₂ je Umsatz: Industrieaktivität geteilt durch denselben Nenner. Die *Zusammensetzung* der Freisetzung ist dagegen unabhängig und beantwortet eine andere Frage: Wie gefährlich ist, was diese Firma freisetzt? Der Score hat damit sieben Indikatoren; die größte Restkorrelation liegt weiterhin bei 0,57, der Median sinkt von 0,20 auf 0,12.

10.2 OSHA: Arbeitsunfaelle

Die Injury-Tracking-Daten 2023 enthalten neben den Unfallfällen auch `total_hours_worked` — damit lässt sich die Standard-Unfallrate je 200 000 Arbeitsstunden rechnen statt einer nackten Fallzahl. 7 353 Betriebsstätten ordnen sich 137 S&P-Firmen zu, mediane Rate 2,38.

Das stärkste Argument für getrennte Dimensionen. Die Arbeitsunfallrate korreliert mit $\rho = +0,04$ ($p = 0,78$) zum Umwelt-Score. Es gibt keinen messbaren Zusammenhang. Wer aus einem guten Emissionswert auf gute Arbeitsbedingungen schließt, schließt auf nichts. Die Giftstoffintensität liegt mit $\rho = -0,35$ dazwischen: teilweise gleichgerichtet, aber nicht redundant.

Trotzdem steht die Unfallrate *nicht* im Score: Sie ist nur für 47 der 116 Firmen gemessen. Bei 59 Prozent Imputation würde ein Score-Indikator vor allem Gruppenmediane transportieren. Sie wird deshalb als eigene Achse ausgewiesen, für die Firmen, die sie haben.

10.3 EIA-923: der physische Nenner, der nicht kam

Die gemessene Größenverzerrung ($\rho = 0,43$) ist ein Nenner-Effekt: Umsatz steht unter dem Bruchstrich. Der naheliegende Fix für Stromerzeuger ist ein physischer Nenner — Tonnen CO₂ je Megawattstunde. Die EIA-923-Erzeugungsdaten und die EIA-860-Eigentümerdatei liefern dafür 257 Mio. MWh für 40 S&P-Firmen.

Der Einbau ist gescheitert, und zwar an der Abdeckung:

Profilgruppe	P1	P2	P3	P4	P5	P6
Anteil mit Erzeugungsdaten	29 %	29 %	34 %	12 %	20 %	0 %

Keine Gruppe erreicht die gesetzte Schwelle von zwei Dritteln. Ein gemischter Nenner innerhalb derselben Vergleichsgruppe — ein Teil der Firmen je MWh, der Rest je Umsatz — wäre schlimmer als ein einheitlich falscher, weil die Perzentile dann zwei verschiedene Größen mischen. Die Kennzahl bleibt deshalb ungenutzt.

Woran es liegt, und was es kosten würde. Die EIA meldet Betreibergesellschaften („Alabama Power Co“), nicht die börsennotierte Mutter (Southern Company). Meine Alias-Liste deckt das für den GHGRP ab, für die EIA nicht. Das ist dieselbe Tochter-Konzern-Tabelle, die im Vergleichsbericht als „am wenigsten skalierbare Stelle der Pipeline“ bezeichnet wurde — und hier schlägt sie erneut zu. Aufwand für den Fix: ein halber Tag Handarbeit. Wirkung: behebt die größte bekannte Verzerrung des Modells für den größten Sektor.

10.4 Was damit erreicht ist — und was nicht

Dimension	Status	Anmerkung
Umwelt (E)	sieben Indikatoren im Score, zwei Zusatzachsen	CO ₂ , Brennstoffmix, Giftstoffe. Scope 2 und 3 fehlen weiter
Soziales (S)	eine Achse, 47 von 116 Firmen	Arbeitsunfälle. Lieferkette, Löhne, Diversität fehlen
Governance (G)	fehlt vollstaendig	Weder Vorstandsvergütung noch Board-Struktur noch Regelverstöße

Damit ist der Anspruch der Challenge — Nachhaltigkeit selbst definieren und die relevanten Dimensionen begründen — zu etwa zwei Dritteln eingelöst. Governance wäre aus SEC-Pflichtangaben (Pay-Ratio seit 2017, Board-Unabhängigkeit) und EPA-ECHO-Verstößen machbar; die CIK-Nummern liegen in der Konstituentenliste bereits vor. Der ECHO-Download in diesem Lauf enthielt nur die Spaltenbeschreibung, nicht die Daten.

11 Was weiterhin nicht geloest ist

Diese Liste ist kein Pflichtteil, sondern der Grund, warum man dem Rest glauben kann.

1. **Governance fehlt vollständig.** Kein Indikator misst Vorstandsvergütung, Board-Struktur, Regelverstöße oder Rechnungslegung. Ein Drittel von ESG ist damit unbesetzt. Das ist die größte inhaltliche Lücke des Berichts.
2. **Soziales nur als Randnotiz.** Eine Achse, 47 von 116 Firmen, und die misst Arbeitssicherheit — nicht Löhne, nicht Lieferkette, nicht Diversität.
3. **Scope 2 und 3 fehlen vollständig.** Bei den meisten Firmen ist das der größte Teil des Fußabdrucks. Kostenlos nicht zu haben.

4. **Die Größenverzerrung ist gemessen, aber offen.** $\rho = 0,432$ ist ein Nenner-Effekt. Physische Nenner je Profilgruppe wären die Lösung; die NAICS-Profile liegen vor, die Produktionsdaten nicht.
5. **Das Band bleibt breit.** Zwölf bis dreizehn Rangplätze. Einzelplatzierungen sind damit nicht zitierfähig, Tertil-Aussagen schon. Das ist ein Ergebnis, keine Lösung.
6. **27 fehlende Umsätze.** Der Auslass-Test entlastet die übrigen Firmen, nicht die 27 selbst.
7. **Überlebensverzerrung.** Für 2011–2023 wird die heutige Indexzusammensetzung verwendet. Firmen, die seither aus dem Index geflogen sind, fehlen — und das sind tendenziell die schlechter laufenden. Die Indexhistorie ist frei verfügbar; der Fix ist ein halber Tag.
8. **Kein externer Maßstab.** Ein kommerzieller ESG-Snapshot als Gegenprobe fehlt in dieser Pipeline. Der Vergleichsbericht maß $\rho = -0,04$ zwischen gemessener und gekaufter Note — ein Befund, den wir hier nicht unabhängig reproduzieren konnten.
9. **Die Profilgruppen sind eine Wahl.** k-Means mit $k = 9$ und Mindestgröße 8 ist begründet, aber nicht alternativlos. Der Einfluss des Gruppenschemas ist mit 0,108 der drittgrößte Einzelfaktor.
10. **Der Rauschanteil ist teilweise weiterhin gesetzt.** Trend-Standardfehler kommen aus der Regression, der Basisfehler auf Emissionsniveau (5 Prozent plus Zuschläge) und die 12 Prozent auf den Umsatz sind begründete Annahmen. Die Verteilungsziehung ist mit 0,187 der größte Einzelfaktor — also hängt ein Gutteil des Bandes an diesen Annahmen.
11. **Der Vintage-Test ist der günstige Fall.** Nur der Emissionsjahrgang variiert, der Umsatz bleibt fest.
12. **US-Bias.** Die EPA kennt nur US-Anlagen. Auslandsanlagen amerikanischer Konzerne fehlen vollständig, ebenso alle Anlagen unter der Meldeschwelle von 25 000 t.

11.1 Was als Nächstes den größten Unterschied macht

Maßnahme	Aufwand	Wirkung
27 fehlende Umsätze nachtragen	Stunden	Intensität gemessen statt geschätzt
Physische Nenner je Profilgruppe	1–2 Tage	behebt die Größenverzerrung
Indexhistorie rekonstruieren	halber Tag	behebt Überlebensverzerrung
20 Firmen von Hand gegen Selbstauskunft	halber Tag	einzige direkte Prüfung der Zuordnung
CEMS-basiertes Rauschen statt Pauschalwert	1 Tag	macht den größten Bandanteil messbar
Scope-2-Daten	offen	größte inhaltliche Lücke

12 Reproduktion

f01_sources.py	Sechs Direktemittenten-Blätter, E/S/I-Audit, vier Matching-Schwellen, zwei Zurechnungsregeln, CEMS-Qualität
f02_features.py	Sechs entkorrelierte Indikatoren mit Fehlerbalken, k-Means-Profilgruppen, acht Datenvarianten
f03_simulation.py	768 Konfigurationen, 76 800 Ranglisten, exakte ANOVA über acht Faktoren
f04_results.py	Rangbänder, zwei Listen, Aggregations-, Imputations-, Vintage- und Größentest, Achse B, PAB-Portfolio
f05_figures.py	Alle Grafiken dieses Berichts
f06_new_sources.py	TRI-Giftstoffe, EIA-Stromerzeugung, OSHA-Unfallraten
f07_supplement.py	Zusatzachsen ohne Imputation, Unabhängigkeitstest

Zufallsstartwert 20260912, damit exakt wiederholbar. Die Tabelle `mc_indicator_draw` wird bewusst nicht materialisiert: bei $116 \text{ Firmen} \times 6 \text{ Indikatoren} \times 76\,800 \text{ Ziehungen}$ wären das 53 Mio. Zeilen. Stattdessen wird je Konfiguration vektorisiert gerechnet und nur die Perzentilmatrix aufbewahrt.

Was dieser Bericht nicht behauptet. Er stellt nicht fest, dass eine bestimmte Firma täuscht. Er trifft keine Aussage über Firmen ohne Anlagendaten. Er misst Scope 1 und nennt das ausdrücklich eine Eingrenzung, keine Vollständigkeit. Und er gibt keine Rangplätze aus, wo die Daten nur Bänder hergeben.

Quellen. US EPA Greenhouse Gas Reporting Program (sechs Direktemittenten-Blätter 2011–2023; Reported Parent Companies; Emissions by Unit and Fuel Type), S&P-500-Konstituentenliste, Science Based Targets initiative Target Dashboard, öffentliche Umsatzdaten, EPA Toxics Release Inventory 2023 (Nationaldatei), EIA-923 und EIA-860 (2023), OSHA Injury Tracking Application 2023. **Methodik.** OECD/JRC Handbook on Constructing Composite Indicators (Nardo et al. 2008); Berg, Kölbel & Rigobon (2022); Khan, Serafeim & Yoon (2016); Andersson, Bolton & Samama (2016); EU-Verordnung 2019/2089.




Figure 5: Eine Profilgruppe im Detail. Punkt ist der Median über alle 768 Konfigurationen, Balken das Intervall vom 10. bis zum 90. Perzentil.




Figure 6: Verteilung der Bandbreiten über alle 116 bewerteten Firmen.




Figure 7: Rückwärtstest über 86 Firmen mit vollständigen Daten.





Figure 8: Die beiden Achsen sind weitgehend unabhängig: ein guter Rang sagt nichts darüber, wie belastbar er ist.






Figure 9: Beide Zusatzachsen gegen den Umwelt-Score, jeweils nur für die Firmen, die tatsächlich Daten haben — ohne Imputation.