

Wie sicher ist diese Note?

Ein Nachhaltigkeitsranking des S&P 500, das seine eigenen Grenzen misst

ETHack 2026 — Challenge #1 — Abschlussbericht

13. September 2026

Kurzfassung. Berkshire Hathaway gilt in jeder Branchensystematik als Finanzunternehmen; 93 Prozent seiner Emissionen stammen aus Kraftwerken. Nachhaltigkeitsnoten bewerten überwiegend, was Firmen über sich selbst schreiben. Dieses Projekt misst ausschließlich, was Behörden festgehalten haben — Emissionen, Arbeitsunfälle, Umweltverstöße, Lohnverfahren, Pflichtberichte — und gibt jede Bewertung als Spanne statt als Platz aus. Ergebnis: 147 von 503 Indexfirmen sind belastbar bewertbar. Die fünf Bewertungsachsen korrelieren praktisch nicht miteinander (max. $\rho = 0,26$), der eigene Score korreliert mit $\rho = 0,005$ zu einem kommerziellen ESG-Rating, und Schweigen ist ein messbares Signal ($p = 0,015$). Das nachgebaute EU-Portfolio halbiert die Emissionsintensität von 529 auf 264 Tonnen je Million USD Umsatz — wobei sich zeigt, dass die Regel das Ergebnis stärker bestimmt als die eigene Bewertung.

Inhalt

1	Was geprüft und was korrigiert wurde	3
2	Die Frage und die Antwort	3
3	Datengrundlage	4
3.1	Quellen	4
3.2	Ein Fehler mit Faktor drei	4
3.3	Zuordnung: Anlagen zu Firmen	5
4	Kennzahlen: zwei Tore	5
4.1	Tor 1: Abdeckung	5
4.2	Tor 2: Korrelation	5
4.3	Was übrig bleibt	6
5	Kennzahlen, die sich nicht gegenseitig erzählen	7
5.1	Das Problem	7
5.2	Der Umbau und sein Nachweis	7
5.3	Vergleichsgruppen aus den Daten	7
5.4	Was mit der Messqualität passierte	7
6	Die Kernfrage: fehlt der Wert, oder gibt es ihn nicht?	8
6.1	Die Konstruktion	8
6.2	Ist Schweigen wirklich ein Signal?	8
6.3	Ein Fehler, den der Test aufgedeckt hat	8

7	Fünf Achsen, nie verrechnet	9
7.1	Der Beleg	9
7.2	Was stattdessen ausgegeben wird	9
8	Die Simulation	9
8.1	Warum nicht eine Rangliste	9
8.2	Woher die Unsicherheit kommt	10
8.3	Die Rangbänder	10
9	Abdeckung: zwei Listen statt einer	11
10	Falsifikation: Versuche, das eigene Ergebnis zu widerlegen	11
10.1	Was hält	11
10.2	Was nicht hält	12
11	Mehr als CO₂: was drei weitere Quellen bringen	12
11.1	EPA TRI: Giftstofffreisetzung	12
11.2	OSHA: Arbeitsunfälle	13
11.3	EIA-923: der physische Nenner, der nicht kam	13
11.4	Was damit erreicht ist — und was nicht	13
12	Vergleich mit einer externen Note	14
13	Vintage: was eine Fortschreibung kostet	14
14	Die Bonusfrage: eine Milliarde unter Netto-null	15
14.1	Die Regel	15
14.2	Umsetzung und Ergebnis	15
14.3	Der unerwartete Befund	15
15	Materialität aus der Tätigkeit, nicht aus dem Label	15
15.1	Die Messlücke	16
16	Was offen bleibt	16
16.1	Was als Nächstes den größten Unterschied macht	17
17	Aufbau und Reproduktion	17
17.1	Pipeline	17
17.2	Determinismus und Skalierung	18
17.3	Ausgabe	18

1 Was geprüft und was korrigiert wurde

Das Projekt ist in mehreren Runden gegen sich selbst gelaufen. Jede Zeile unten ist ein benannter Kritikpunkt, die Gegenmaßnahme und das gemessene Ergebnis danach.

	Kritikpunkt	Gegenmaßnahme	Gemessenes Ergebnis
K1	Nur ein von sechs Direktemittenten-Blättern gelesen	Alle sechs geladen, Lieferanten und Injektion ausgeschlossen	2 578,6 Mt — trifft die EPA-Zahl exakt
K2	Doppelzählung durch Lieferantenzeilen ungeprüft	E/S/I-Audit als Pflichtschritt	naive Summe wäre Faktor 3,19 zu hoch
K3	Matching-Schwelle willkürlich gesetzt	Vier Schwellen als Datenvariante	Effekt gemessen: 0,003 der Streuung
K4	Zurechnungsregel versteckt im Code	Equity-Share und operative Kontrolle als Achse	Effekt gemessen: 0,013
K5	Kennzahlen korreliert, Multiplikation wirkungslos	Trendpaar ersetzt durch Trendabweichung und Momentum	Aggregationswahl verschiebt jetzt 7,7 pp statt 0
K6	GICS ist die falsche Vergleichsgruppe	k-Means über NAICS-Emissionsprofile	Berkshire liegt bei 29 Versorgern statt bei Banken
K7	Messqualität nicht erfasst	CEMS-Anteil aus dem EPA-Feld Unit Reporting Method	korreliert 0,65 mit Kohle — deshalb auf Nebenachse
K8	Vintage nicht geprüft	Rückwärtstest, beidseitig	Intervall statt Punkt, 9 bis 37 % über 10 pp
K9	Imputation als unkritisch behauptet	Auslass-Test ohne die betroffenen Firmen	Reihenfolge unverändert ($\rho = 1,000$)
K10	Größenverzerrung ungeprüft	Rangkorrelation Bilanzsumme gegen Perzentil	nach Korrektur ρ zwischen $-0,07$ und $+0,07$
K11	Eine Liste behauptet, die es nicht gibt	Zwei Listen mit Begründung je Firma	147 bewertbar, 356 nicht
K12	Externer Maßstab fallengelassen	Vergleich gegen einen öffentlichen Datensatz	$\rho = 0,005$ ($n = 65$)
K13	Portfolio auf absoluten Tonnen	PAB auf Emissionsintensität	528,7 → 264,4 t je Mio. USD

2 Die Frage und die Antwort

Die Challenge verlangt ein datengetriebenes Rahmenwerk, das die Nachhaltigkeit der S&P-500-Firmen quantifiziert und vergleichbar macht. Die Definition von „Nachhaltigkeit“ ist ausdrücklich den Teilnehmenden überlassen.

Unsere Festlegung ist eine Abgrenzung, keine Philosophie:

Wir messen physische Lasten und dokumentiertes Verhalten aus Behördendaten, innerhalb der Branche, mit ausgewiesener Unsicherheit. Nicht gemessen werden: Absichten, Strategien, Berichtsqualität, eingekaufter Strom (Scope 2) und die Lieferkette (Scope 3).

Der Grund für diese Abgrenzung ist ein Befund, kein Vorurteil: Unser gemessener Score korreliert mit $\rho = 0,005$ ($n = 65$, $p = 0,97$) zu einem öffentlich zugänglichen kommerziellen ESG-Datensatz. Zwei Systeme, die denselben Namen tragen und verschiedene Größen messen.

3 Datengrundlage

3.1 Quellen

Quelle	Was daraus stammt	Umfang
EPA GHGRP	Scope-1-Emissionen je Anlage, 2011–2023	10 518 Anlagen, 100 347 Anlage-Jahr-Werte
EPA Parent Companies	Anlage → Konzern inkl. Eigentumsanteil	122 960 Zuordnungen
EPA Unit & Fuel Data	Brennstoffmix, Messverfahren je Aggregat	172 150 Einheiten-Jahre
EPA TRI	Giftstofffreisetzung, Krebserreger-Kennzeichen	183 Indexfirmen
EPA ECHO	Verstoßquartale, Strafen, Inspektionen	136 Indexfirmen
OSHA ITA	Arbeitsunfälle je 200 000 Stunden	323 Indexfirmen
DOL WHD	Lohnverfahren, nachgezahlte Löhne	Firmenebene
SBTi	validierte Klimaziele, zurückgezogene Zusagen	15 605 Einträge, 227 Indexfirmen
WBA	SDG-orientierte Bewertungen	218 Indexfirmen
SEC-Pflichtberichte	Umsatz, Bilanzsumme, Cashflow	482–498 Indexfirmen

3.2 Ein Fehler mit Faktor drei

Die EPA-Tabelle enthält drei Arten von Meldern, die sich nicht addieren lassen: *Direktemittenten* (Scope 1), *Lieferanten* (der Kohlenstoff in verkauften Kraftstoffen, der später beim Kunden freigesetzt wird) und *Injektion* (eingelagertes, also gerade nicht ausgestoßenes CO₂).

Kategorie	2023, Mt CO ₂ e	Behandlung
Direktemission (E)	2 578,6	verwendet
Lieferant (S)	5 631,0	ausgeschlossen (Doppelzählung)
Injektion (I)	16,4	ausgeschlossen (nicht ausgestoßen)
naive Summe	8 226,0	Faktor 3,19 zu hoch

Der Fehler hätte plausibel ausgesehen. Ein Ranking auf der naiven Summe hätte Raffineriebetreiber ans Ende jeder Liste gesetzt. Das GHG-Protokoll untersagt diese Doppelzählung ausdrücklich: Die Lieferantenmenge ist die Scope-1-Emission der Kunden. **Die harte Gegenprobe:** Nach Einlesen aller sechs Direktemittenten-Blätter ergeben sich 2 578,6 Mt — die EPA veröffentlicht für dasselbe Berichtsjahr 2,58 Mrd. t. Eine Punktlandung, und die einzige externe Validierung der Datenaufbereitung, die ohne gekaufte Daten möglich ist.




Figure 1: Die drei Meldekategorien im Verhältnis.

3.3 Zuordnung: Anlagen zu Firmen

Behörden kennen Anlagen, keine börsennotierten Firmen. Der Konzernname steht als Freitext im Datensatz. Die Zuordnung läuft dreistufig: exakter Abgleich nach Normalisierung (Rechtsformen und Füllwörter entfernt), manuelle Alias-Liste für Fälle wie „Florida Power & Light“ → NextEra Energy, und unscharfer Textabgleich für den Rest.

Entscheidend: Jede Zuordnung trägt einen `match_score`. Dieser Wert verschwindet nicht, sondern fließt in den Messfehler ein. Eine wacklige Namenszuordnung wird damit zu Rauschen im Modell statt zu einer stillen Fehlerquelle.

Wie viel das ausmacht, ist gemessen: Vier Matching-Schwellen (85/90/92/95) wurden als eigene Datenvariante durchgerechnet. Ihr Beitrag zur Gesamtstreuung beträgt 0,003. Ebenso die Zurechnungsregel (Eigentumsanteil gegen operative Kontrolle): 0,013. Beides galt vorab als großes Risiko und ist es nicht.

4 Kennzahlen: zwei Tore

Aus den Rohdaten entstehen 27 Bewertungskennzahlen. Zwei Prüfungen entscheiden, welche davon in den Score kommen.

4.1 Tor 1: Abdeckung

Eine Kennzahl, die für weniger als 60 Prozent der Firmen vorliegt, trägt im Score vor allem Gruppenmediane. Sie wandert auf eine Nebenachse und wird separat ausgewiesen — nicht imputiert.

Betroffen unter anderem die Arbeitsunfallrate in der ursprünglichen Fassung (47 von 116 Firmen) und die SBTi-Zielraten (26 von 115).

4.2 Tor 2: Korrelation

Eine Kennzahl, die mit $|\rho| > 0,30$ zur CO₂-Intensität läuft, misst dasselbe ein zweites Mal. Acht Kandidaten sind daran gescheitert:

Kennzahl	ρ	Deutung
Scope-1-Emissionen absolut	0,94	derselbe Zähler
CO ₂ am Schornstein gemessen	0,72	dieselbe Größe, andere Quelle
Giftstofffreisetzung	0,59	Industrieaktivität je Umsatz
CO ₂ je Megawattstunde	0,45	andere Normierung derselben Größe
Umweltstrafen	0,42	wer viel ausstößt, wird öfter bestraft
Anlagen mit schwerem Verstoß	0,40	dito
Krebserregende Freisetzung, absolut	0,42	Aktivitätsmaß
WBA Just Transition	0,37	

Die teuerste Streichung. Von drei ECHO-Kennzahlen überlebt genau eine. Die Regeltreue-Achse steht damit auf einem Bein. Das ist der Preis für die Konsequenz: Lieber eine saubere Kennzahl als drei, die dasselbe sagen.

Ein Gegenbeispiel zeigt, wie die Prüfung Entscheidungen verbessert: Die Freisetzungsmenge aus dem TRI fällt durch ($\rho = 0,59$), der Anteil krebserregender Stoffe daran besteht sie ($\rho = 0,01$). Nicht wie viel eine Firma freisetzt ist die unabhängige Information, sondern wie gefährlich es ist.

4.3 Was übrig bleibt

Achse	Kennzahlen	Inhalt
Umwelt	3	CO ₂ -Intensität, Intensitätstrend, Trend der absoluten Tonnen
Soziales	6	Unfallrate (DART), Todesfälle, Lohnverfahren, nachgezahlte Löhne, betroffene Beschäftigte, WBA Social
Regeltreue	1	Verstoßquartale je Anlage
Offenheit & Ziele	7	SBTi validiert, Zusage zurückgezogen, Intensitäts-Illusion, Basisjahr-Bequemlichkeit, WBA Transitionsplan, WBA Beitrag, WBA Nature
Tragfähigkeit	Ampel	Eigenfinanzierung, Substanzerhalt, Schuldendienst




Figure 2: Korrelationsmatrix der Score-Kennzahlen nach beiden Toren.

5 Kennzahlen, die sich nicht gegenseitig erzählen

5.1 Das Problem

Eine frühere Fassung hatte zwei Trendkennzahlen, die mit $\rho = 0,64$ korrelierten, weil sie aus derselben Emissionsreihe stammten. Die Folge: Die multiplikative Aggregation — methodisch das Herzstück, weil sie verhindert, dass eine Bestnote eine katastrophale zurückkauft — veränderte im Median *gar nichts*. Nicht-Kompensierbarkeit kann nur dort greifen, wo es etwas zu kompensieren gibt.

5.2 Der Umbau und sein Nachweis

Der absolute Trend wurde durch die *Abweichung vom Gruppenmedian* ersetzt, dazu kam Momentum (kurzer minus langer Trend). Beide sind niveaunabhängig.

Aggregationstest	vorher	nachher
mediane Abweichung Addition gegen Multiplikation	0,0 pp	7,7 pp
Anteil der Firmen über 10 pp	8,9 %	41,4 %

Der Fix greift, und das ist messbar. Die Entscheidung zwischen Addition und Multiplikation verändert jetzt bei gut 40 Prozent der Firmen die Einordnung spürbar. Vorher war sie folgenlos.

Und er hat einen Preis. Nach der Entkorrelierung wurde das Rangband *breiter*, nicht schmaler. Solange zwei Kennzahlen dasselbe sagten, waren Gewichtung und Aggregation weitgehend wirkungslos, und das Ergebnis wirkte stabiler, als es war. Die frühere Enge war zum Teil ein Artefakt redundanter Indikatoren — die unangenehmste Erkenntnis des Projekts.

5.3 Vergleichsgruppen aus den Daten

GICS sortiert Firmen nach Umsatzquellen, nicht nach Emissionsprofil. Berkshire Hathaway steht mit über 50 Mio. t unter *Financials* und würde gegen Banken verglichen — ein Ergebnis, das nichts über die Firma sagt, nur über die Taxonomie.

Die Gegenmaßnahme: k-Means über das NAICS-Emissionsprofil jeder Firma, mit erzwungener Mindestgröße von acht.

Der Test. Berkshire Hathaway landet in einer Profilgruppe mit 29 Versorgern und einem zweiten Finanztitel (Ares Management, ebenfalls mit Kraftwerksbeteiligungen). Die Gruppe wurde nie mit dieser Absicht gebaut; sie ergibt sich aus den Anlagendaten.

5.4 Was mit der Messqualität passierte

Das EPA-Feld Unit Reporting Method unterscheidet berechnete (Tier 1–3) von kontinuierlich gemessenen Emissionen (Tier 4 / CEMS). Der Anteil gemessener Emissionen lag als Kennzahl nahe.

Die Korrelationsprüfung hat das verhindert: $\rho = 0,65$ zum Kohleanteil, $\rho = 0,62$ zur Intensität. Der CEMS-Anteil misst im Wesentlichen „betreibt diese Firma Kohlekraftwerke“. Er steht deshalb auf der Glaubwürdigkeitsachse — als Aussage über Berichtsqualität, nicht über Nachhaltigkeit.

6 Die Kernfrage: fehlt der Wert, oder gibt es ihn nicht?

Dies ist die Stelle, an der sich das Verfahren von kommerziellen Ratings unterscheidet.

Eine Bank hat keine Emissionsdaten, *weil sie keine meldepflichtige Anlage betreibt* — nicht, weil sie schweigt. Eine Firma ohne SBTi-Ziel könnte eines setzen, tut es aber nicht. Der erste Fall ist keine Information, der zweite sehr wohl.

6.1 Die Konstruktion

Jede Zelle bekommt einen von fünf Zuständen:

Zustand	Bedeutung
offengelegt	Wert liegt vor
nicht anwendbar	Firma betreibt keine Anlage dieser Art
nicht berechenbar	von uns abgeleitete Größe, zu wenige Jahre
nicht erwartet	unter 30 Prozent der Branche berichtet es
verschwiegen	anwendbar, Branche berichtet es, hier fehlt es

Der Offenlegungsscore ist die Erfüllungsquote der *erwarteten* Angaben:

$$\text{Score} = \frac{\#\{\text{offengelegt} \wedge \text{erwartet}\}}{\#\{\text{erwartet}\}}, \quad \text{erwartet} = \text{anwendbar} \wedge \text{Peer-Quote} \geq 30 \%$$

Median über alle Firmen: 71 Prozent.

6.2 Ist Schweigen wirklich ein Signal?

Die Konstruktion ruht auf einer Theorie (Dye 1985): Wer Gutes zu berichten hätte, berichtet es. Ob das in *diesen* Daten gilt, wurde geprüft — Firmen, die zu einem Thema schweigen, gegen Firmen, die es berichten, verglichen auf Kennzahlen, die beide haben und die nichts mit Offenlegung zu tun haben.

Firmen ohne validiertes SBTi-Klimaziel liegen bei der Regeltreue im 45. Perzentil, Firmen mit Ziel im 71. Differenz 25,5 Perzentilpunkte, abgesichert per Permutationstest über 1 000 Durchläufe: $p = 0,015$ ($n = 34$ gegen 55). Wer sich kein Ziel setzt, hat messbar mehr behördlich festgestellte Umweltverstöße.

Die ehrliche Hälfte: Bei 18 von 20 Vergleichen fand sich *kein* Unterschied. Schweigen zu Lohnverfahren oder Unfällen sagt nichts über das Umweltverhalten. Das Signal gilt für Klimaziele, nicht allgemein.

6.3 Ein Fehler, den der Test aufgedeckt hat

Im ersten Durchlauf schienen Schweigende beim Umwelttrend *besser* dazustehen. Ursache: Selbst berechnete Größen (Trends, Warnsignale) waren als „verschwiegen“ gezählt worden, wenn sie fehlten. Ein fehlender Trend bedeutet aber zu wenige Jahresdaten, nicht Schweigen der Firma. Nach Einführung des Zustands „nicht berechenbar“ verschwand der Effekt vollständig.

7 Fünf Achsen, nie verrechnet

7.1 Der Beleg

Achsenpaar	ρ	95%-Bootstrap
Umwelt / Soziales	+0,26	[+0,10; +0,41]
Regeltreue / Offenheit	+0,16	[−0,01; +0,33]
Soziales / Offenheit	+0,08	[−0,09; +0,25]
Soziales / Regeltreue	+0,08	[−0,08; +0,25]
Umwelt / Regeltreue	+0,02	[−0,15; +0,20]
Umwelt / Offenheit	+0,01	[−0,16; +0,18]
Tragfähigkeit / alle	0,00 bis 0,08	

500 Bootstrap-Durchläufe. Die größte Obergrenze liegt bei +0,41, alle übrigen Konfidenzintervalle schließen die Null ein.

Daraus folgt eine methodische Aussage, keine Meinung. Wenn fünf Dimensionen nichts voneinander wissen, ist ihr Mittelwert kein „Gesamtwert“ — es ist ein Durchschnitt aus Unabhängigem, der keine der fünf mehr trägt. Eine einzelne ESG-Note ist damit nicht ungenau, sondern konzeptionell falsch.

7.2 Was stattdessen ausgegeben wird

Fünf Noten nebeneinander, dazu die *schwächste Achse* je Firma. Eine gute Note kauft eine schlechte nicht zurück. Das entspricht dem Minimumprinzip und vermeidet die Verrechnung.




Figure 3: Zwei Zusatzachsen gegen den Umwelt-Score, nur für Firmen mit tatsächlichen Daten. Die Arbeitsunfallrate korreliert mit $\rho = +0,04$ ($p = 0,78$) — kein messbarer Zusammenhang.

8 Die Simulation

8.1 Warum nicht eine Rangliste

Beim Bau eines zusammengesetzten Indikators fallen Dutzende Entscheidungen an, die alle vertretbar sind und alle das Ergebnis verändern. Das OECD/JRC-Handbuch verlangt deshalb eine Unsicherheits- und Sensitivitätsanalyse als Pflichtschritt. In der Praxis wird sie fast immer weggelassen.

Statt einer Kombination werden alle durchgerechnet:

Dimension	Stufen	Ausprägungen
Normalisierung	3	Rang, gestutzter Z-Wert, Min-Max
Aggregation	2	Addition, Multiplikation
Vergleichsebene	3	Sektor, Teilbranche, global
Achsenengewichtung	4	gleich, umweltlastig, ausgewogen, verhaltenslastig
Lückenfüllung	2	Gruppenmedian, Gesamtmedian
Mindestzahl Achsen	3	2, 3, 4
Ziehungen		100 je Konfiguration, identische Zufallszahlen

Weil jede Konfiguration dieselben Ziehungen sieht, ist das Design voll faktoriell — die Varianzzerlegung ist damit **exakt** berechenbar statt geschätzt.

8.2 Woher die Unsicherheit kommt

Faktor	Haupteffekt	Totaleffekt
Verteilungsziehung (Datenrauschen)	0,368	0,837
Vergleichsebene	0,040	0,115
Achsenengewichtung	0,035	0,120
Aggregation	0,021	0,094
Normalisierung	0,020	0,101
Mindestzahl Achsen	0,003	0,384

Der große Anteil der Verteilungsziehung ist kein Erfolg, sondern eine Einschränkung — siehe Abschnitt 16.

8.3 Die Rangbänder

Medianes 80-Prozent-Band der Umweltachse: 29,5 Perzentilpunkte. Nach Zahl belegter Achsen:

Belegte Achsen	Firmen	Median-Band
2	173	79,5 pp
3	66	77,9 pp
4	129	43,0 pp

Der entscheidende Befund zur Abdeckung. Firmen mit dünner Datenlage bekommen kein unsicheres Ergebnis — sie bekommen ein Band, das fast die gesamte Skala umfasst. Ihr Platz wäre reines Rauschen. Erst bei vollständiger Abdeckung wird die Einordnung aussagekräftig. Das ist der Grund für die Schwelle bei drei Achsen.

Wie viele Firmenpaare lassen sich überhaupt unterscheiden, also ohne Überlappung der Bänder?

Achse	entscheidbare Paare
Regeltreue	48,3 %
Umwelt	23,0 %
Soziales	20,1 %
Offenheit & Ziele	15,8 %

9 Abdeckung: zwei Listen statt einer




Figure 4: Anteil bewertbarer Indexmitglieder je GICS-Sektor.

Kategorie	Firmen	Anteil	
belastbar bewertbar (≥ 3 Achsen)	147	29 %	Liste 1
alle vier Achsen belegt	129	26 %	
mit irgendeiner Angabe	467	93 %	
nicht bewertbar	356	71 %	Liste 2, mit Begründung

Die Spanne reicht von Utilities (29 von 31) bis Real Estate (1 von 30).

Die 467 sind eine Schözzahl. Sie zählt jede Firma mit, von der irgendein Wert vorliegt — bei 96 Firmen ist das genau eine Achse. Belastbar sind 147. Wer behauptet, den ganzen S&P 500 aus kostenlosen Quellen bewertet zu haben, hat entweder Daten gekauft oder geschätzt.

Warum überhaupt branchenintern? Weil die Branchenzugehörigkeit allein **49,9 Prozent** der Varianz der logarithmierten CO₂-Intensität erklärt. Ein globales Ranking würde zur Hälfte nur messen, in welcher Branche eine Firma zufällig ist. Bei einem Wechsel von branchenintern auf global wechseln 12,4 Prozent der Firmen das Drittel.

10 Falsifikation: Versuche, das eigene Ergebnis zu widerlegen

Zehn Experimente wurden am fertigen Modell gerechnet. Drei davon gingen unbequem aus.

10.1 Was hält

Größenverzerrung: keine. Die Literatur berichtet, dass große Firmen bessere ESG-Noten bekommen. Nach branchenrelativer Rechnung ist davon nichts übrig: ρ zwischen $-0,07$ und $+0,07$ auf allen vier Achsen, nichts signifikant. Eine frühere Fassung hatte hier noch $\rho = 0,43$.

Achsen-Unabhängigkeit: stabil (Bootstrap, siehe oben).

Schweigen-Signal: bestätigt (Permutationstest, $p = 0,015$).

Manipulationsforensik: unauffällig. Zwei Standardverfahren wurden auf die gemeldeten Emissionsdaten angewandt. An der Meldeschwelle von 25 000 t zeigt sich keine Lücke, die auf

gezieltes Unterschreiten hindeutet — der Sprung dort ist die einsetzende Meldepflicht selbst. Und die Ziffernverteilung (Benford, erste Ziffer) weicht bei *gerechneten* Werten sogar weniger ab (MAD 0,0092) als bei kontinuierlich *gemessenen* (0,0148); Rundung auf glatte Hunderter liegt bei beiden auf Zufallsniveau. Kein Hinweis auf Manipulation.

10.2 Was nicht hält

Die Spannen sind nicht enger als bei Zufallsdaten. Die Emissionswerte wurden branchenintern durchgewürfelt — jede Firma erhält zufällig den Wert einer anderen — und die Bänder neu gerechnet. Ergebnis: echte Daten 29,5 pp, gewürfelte Daten 21,0 pp. Die gewürfelten sind *enger*.

Das bedeutet: Die Breite unserer Spannen entsteht überwiegend aus den Fehlerbalken-Annahmen, nicht aus der Datenstruktur. Die ehrliche Formulierung lautet deshalb: *Die Spannen zeigen, wie stark das Ergebnis an unseren eigenen Annahmen hängt* — nicht, wie unsicher die Daten sind. Das deckt sich mit dem ANOVA-Befund, dass die Verteilungsziehung mit 0,368 der größte Einzelfaktor ist.

Die Peer-Schwelle ist ein Bruchpunkt. Der Offenlegungsscore wurde mit Schwellen von 10 bis 60 Prozent gerechnet. Bis 30 Prozent bleibt die Rangfolge praktisch identisch ($\rho \geq 0,998$ zur 10-Prozent-Variante). Bei 40 Prozent bricht sie ein ($\rho = 0,557$), der Median springt von 82 auf 100. Unsere Wahl von 30 Prozent liegt genau am Rand des stabilen Bereichs.

Die fünfte Achse besteht ihren eigenen Test nicht. Der Tragfähigkeitsindex wurde aus einem einzelnen Geschäftsjahr rekonstruiert, weil die Zehnjahreshistorie fehlt. Er korreliert mit $\rho = 0,52$ zur Gewinnmarge; die vollständige Fassung erreicht 0,12. Er belohnt also noch Profit. Getestet wurden Sättigungspunkte bis hinunter zu 0,02 — es hilft nicht. Die Achse ist im Dashboard als „vorläufig“ gekennzeichnet.

11 Mehr als CO₂: was drei weitere Quellen bringen

Bis zu einem bestimmten Punkt war jede Kennzahl ein Blick auf dieselbe Emissionsreihe. Damit konnte die multiplikative Aggregation nur zwischen Varianten desselben Themas unterscheiden, und der Begriff „Nachhaltigkeit“ war nicht gedeckt. Drei Quellen wurden geprüft.

11.1 EPA TRI: Giftstofffreisetzung

Der Nationaldatensatz 2023 enthält 78 648 Meldezeilen mit Luft-, Wasser- und Bodenfreisetzungen je Chemikalie, dazu ein Krebserreger-Merkmal. Über dieselbe Namenszuordnung wie beim GHGRP ergeben sich 14 825 Zeilen für 183 Indexfirmen, zusammen rund 250 000 t freigesetzte Stoffe.

Die Korrelationsprüfung entschied gegen die naheliegende Kennzahl:

Kandidat	$ \rho $ zur CO ₂ -Intensität	Entscheidung
Giftstoffe je Umsatz	0,59	verworfen
Anteil krebserregender Stoffe	0,01	in den Score

Die Freisetzungsmenge je Umsatz misst weitgehend dasselbe wie CO₂ je Umsatz: Industrieaktivität geteilt durch denselben Nenner. Die *Zusammensetzung* beantwortet eine andere Frage — wie gefährlich ist, was diese Firma freisetzt?

11.2 OSHA: Arbeitsunfälle

Die Injury-Tracking-Daten enthalten neben den Unfallfällen auch `total_hours_worked`. Damit lässt sich die Standardrate je 200 000 Arbeitsstunden rechnen statt einer nackten Fallzahl. 323 Indexfirmen werden erreicht, mediane Rate 2,38.

Das stärkste Argument für getrennte Dimensionen. Die Arbeitsunfallrate korreliert mit $\rho = +0,04$ ($p = 0,78$) zum Umwelt-Score. Es gibt keinen messbaren Zusammenhang. Wer aus einem guten Emissionswert auf gute Arbeitsbedingungen schließt, schließt auf nichts. Die Giftstoffintensität liegt mit $\rho = -0,35$ dazwischen: teilweise gleichgerichtet, aber nicht redundant.

11.3 EIA-923: der physische Nenner, der nicht kam

Die gemessene Größenverzerrung ist ein Nenner-Effekt: Umsatz steht unter dem Bruchstrich. Der naheliegende Fix für Stromerzeuger ist ein physischer Nenner — Tonnen CO₂ je Megawattstunde. Die EIA-923-Erzeugungsdaten und die EIA-860-Eigentümerdatei liefern dafür 257 Mio. MWh für 40 Indexfirmen.

Der Einbau ist gescheitert, und zwar an der Abdeckung:

Profilgruppe	P1	P2	P3	P4	P5	P6
Anteil mit Erzeugungsdaten	29 %	29 %	34 %	12 %	20 %	0 %

Keine Gruppe erreicht die gesetzte Schwelle von zwei Dritteln. Ein gemischter Nenner innerhalb derselben Vergleichsgruppe — ein Teil der Firmen je MWh, der Rest je Umsatz — wäre schlimmer als ein einheitlich falscher, weil die Perzentile dann zwei verschiedene Größen mischen. Die Kennzahl bleibt ungenutzt.

Woran es liegt. Die EIA meldet Betreibergesellschaften („Alabama Power Co“), nicht die börsennotierte Mutter (Southern Company). Das ist dieselbe Tochter-Konzern-Zuordnung, die schon beim GHGRP die aufwendigste Stelle war. Aufwand für den Fix: ein halber Tag Handarbeit. Wirkung: behäbe die größte bekannte Verzerrung für den größten Sektor.

11.4 Was damit erreicht ist — und was nicht

Dimension	Status	Anmerkung
Umwelt (E)	im Score, plus Nebenachsen	CO ₂ , Brennstoffmix, Giftstoffe. Scope 2 und 3 fehlen
Soziales (S)	im Score	Arbeitsunfälle, Lohnverfahren. Lieferkette und Diversität fehlen
Governance (G)	im Score, eine Kennzahl	Regeltreue gegenüber Umweltbehörden. Vorstandsvergütung und Board-Struktur fehlen

Damit ist der Anspruch der Challenge — Nachhaltigkeit selbst definieren und die relevanten Dimensionen begründen — weitgehend, aber nicht vollständig eingelöst. Klassische Governance-Kennzahlen aus SEC-Pflichtangaben (Pay-Ratio, Board-Unabhängigkeit) wären machbar; die CIK-Nummern liegen vor.

12 Vergleich mit einer externen Note

Ein öffentlich zugänglicher, KI-gestützt zusammengetragener Emissionsdatensatz eines Anbieters liefert einen eigenen Score für 223 Indexfirmen. 65 davon überschneiden sich mit unserem bewertbaren Universum.

Ebene	<i>n</i>	ρ	<i>p</i>
gesamt	65	+0,005	0,97
Energy	11	−0,41	0,21
Utilities	19	+0,05	0,85
Materials	9	+0,07	0,86
Industrials	5	+0,90	0,04

Kein nachweisbarer Zusammenhang. Das deckt sich mit Berg, Kölbel & Rigobon (2022): Anbieter messen im Wesentlichen sich selbst. Nach Sektor kippt das Vorzeichen, aber bei $n = 5$ bis 19 ist das Rauschen, kein Befund.

Die Interpretation ist zurückhaltender, als sie klingt. Dieser Score misst Scope 1 aus Behördenmeldungen; der externe Datensatz mischt Scope 1 bis 3 aus Berichten und Schätzungen (Median 33 Prozent geschätzt, einzelne Firmen über 99 Prozent) über wechselnde Jahre. Zwei Größen, die nicht dasselbe messen, müssen nicht korrelieren. Die Aussage lautet nicht „einer liegt falsch“, sondern: Wer eine Nachhaltigkeitsnote verwendet, muss wissen, welche Größe darin steckt. Der Datensatz dient deshalb nur als Vergleichsmaßstab, nie als Eingang.

13 Vintage: was eine Fortschreibung kostet

Die Emissionsreihe endet mit dem Berichtsjahr 2023. Die praktische Frage ist nicht, ob das ideal ist, sondern was eine Fortschreibung kostet. Messbar wird das rückwärts: Emissionen aus 2021 mit heutigen Nennern kombinieren und gegen die echte Rangliste halten.

Fall	ρ	Median	p90	über 10 pp
nur Emissionen alt (Untergrenze)	0,98	0,0 pp	6,5 pp	9,3 %
Emissionen und Nenner alt	0,96	3,1 pp	12,9 pp	18,2 %
Vergleichsrechnung, andere Gruppenbildung	0,84	7,4 pp	30,0 pp	37,3 %

Der mittlere Fall stört den Nenner mit einer realistischen Zweijahresdrift (Median +12 Prozent, Streuung 20 Prozent, 200 Wiederholungen), weil echte Umsatzdaten für 2021 nicht vorliegen.

Ein eigener Fehler, protokolliert. Ein erster Versuch, den alten Umsatz aus der Emissionsentwicklung zu skalieren, war zirkulär — er kürzte sich in der Intensität exakt weg und lieferte $\rho = 1,00$. Das steht hier, weil es genau die Art Fehler ist, die eine Unsicherheitsanalyse aufdecken soll, auch im eigenen Code.

Praktische Regel: Für die Kennzeichnung fortgeschriebener Werte wird die *Obergrenze* verwendet — Band um 30 Perzentilpunkte aufweiten, Datenalter je Firma anzeigen. Wer die 6,5 pp nimmt, rechnet sich die Fortschreibung schön.

14 Die Bonusfrage: eine Milliarde unter Netto-null

14.1 Die Regel

Der EU *Paris-Aligned Benchmark* (Verordnung 2019/2089) verlangt mindestens 50 Prozent weniger CO₂-Intensität als der Vergleichsindex, danach 7 Prozent Reduktion pro Jahr — und **klimaintensive Branchen dürfen nicht untergewichtet werden**.

Der letzte Punkt ist der inhaltliche Kern: Wer die Ölindustrie verkauft, ändert nichts an der Atmosphäre. Die Anlagen gehören dann jemand anderem. Nur eine Umschichtung *innerhalb* der Branche erzeugt Wettbewerbsdruck.

14.2 Umsetzung und Ergebnis

Anlageuniversum	131 Firmen mit Note und Intensität
ausgeschlossen wegen wirtschaftlicher Lage	33
Benchmark-Intensität	528,7 t CO ₂ e je Mio. USD
Portfolio-Intensität	264,4
Reduktion	–50,0 %
Sektorregel	erfüllt, alle elf Branchen
Gewichtsabweichung vom Index	0,098
Titel im Portfolio	89
größtes Einzelgewicht	5,61 %

Zwei Ergänzungen über die Regel hinaus: Wirtschaftlich gefährdete Firmen werden ausgeschlossen — wer seine Beschäftigten nicht bezahlen kann, ist in keinem praktischen Sinn nachhaltig. Und unsichere Noten werden gedämpft: Wo das Band breit ist, fällt die Wette kleiner aus.

14.3 Der unerwartete Befund

Das Portfolio wurde fünfmal gerechnet, jedes Mal mit einem anderen Schwerpunkt.

Die Portfolios überlappen zu 86 bis 95 Prozent. Ob nach Umwelt, Soziales oder Regeltreue getiltet wird, ändert kaum etwas. Die Halbierung der Intensität und die Sektorneutralität legen das Ergebnis weitgehend fest.

Nachgemessen: Bei Tiltstärke null sind die Portfolios *identisch* (100 Prozent Überlappung). Erst bei Verzehnfachung gehen sie auseinander (62 Prozent), wobei die Abweichung vom Index von 0,099 auf 0,113 steigt.

Die EU-Regel bindet stärker als unsere Note. Das ist ein Befund über die Regulierung, nicht über unsere Achsen.

Einschränkung. Optimiert wird auf Scope-1-Intensität; die EU-Regel meint Scope 1, 2 und 3. Der gezeigte Pfad ist die geforderte Trajektorie, keine Prognose.

15 Materialität aus der Tätigkeit, nicht aus dem Label

Der übliche Weg: Eine Tabelle ordnet jedem Sektor Themen zu, jede Firma erbt das Profil ihres Sektors. Eine Firma, die drei Dinge gleichzeitig tut, bekommt trotzdem nur ein Profil.

Hier anders: Jede Anlage hat einen NAICS-Code, also eine dokumentierte Tätigkeit. Das Materialitätsprofil einer Firma ist die emissionsgewichtete Mischung der Profile ihrer Tätigkeiten.

Firma	GICS-Label	Anteil	tatsächliche Haupttätigkeit
Berkshire Hathaway	Financials	93,5 %	Stromerzeugung
Loews Corporation	Financials	94,8 %	Pipelines
3M	Industrials	69,2 %	Chemie (vier Tätigkeiten)

27 der bewerteten Firmen haben mehr als eine relevante Tätigkeit. Eine Sektortabelle kann das grundsätzlich nicht abbilden — sie vergibt ein Profil pro Firma.

15.1 Die Messlücke

Für jedes als relevant erkannte Thema wurde geprüft, ob es aus freien Quellen überhaupt messbar ist. Die Differenz ist das eigentliche Ergebnis.

Profilgruppe	relevant	voll	teilweise	Lücke
Öl- und Gasförderung	9	3	3	3
Chemie	9	3	2	4
Stromerzeugung	9	2	3	4
Fahrzeugbau	5	1	2	2
Elektronikfertigung	4	2	0	2
sonstige Industrie	6	1	2	3
gesamt	42	12	12	18

43 Prozent blind. Von 42 relevanten Thema-Gruppe-Paaren sind 18 aus freien Quellen überhaupt nicht messbar: Wasser, Abfall, Flächennutzung, Lieferkette, physisches Klimarisiko. Das ist keine Lücke dieser Arbeit, sondern der Datenlandschaft — und sie wird hier ausgewiesen statt geschätzt.

Einschränkung. Die Zuordnung Tätigkeit → Themen ist selbst gesetzt, nach der NAICS-Tätigkeitsbeschreibung. Transparent und begründet, aber nicht gemessen. Und die Gewichtung nach Emissionen unterschätzt Tätigkeiten, die wenig CO₂ erzeugen, aber andere Lasten — Elektronikfertigung etwa.

16 Was offen bleibt

Diese Liste ist der Grund, warum man dem Rest glauben kann.

1. **Scope 2 und 3 fehlen vollständig.** Bei den meisten Firmen der größere Teil des Fußabdrucks. Bei Banken praktisch der gesamte. Kostenlos nicht verfügbar. Die kalifornische Offenlegungspflicht (SB 253) ändert das ab 2027.
2. **Die Spannen ruhen auf gesetzten Annahmen.** Belegt durch den Zufallsvergleich. Die Trend-Standardfehler stammen aus der Regression und sind echt; der Basisfehler auf Emissionsniveau (5 Prozent plus Zuschläge) und die 12 Prozent auf den Umsatz sind begründet, aber nicht gemessen.
3. **Abdeckung 147 von 503.** Strukturell, nicht zufällig: Meldepflichten erfassen physische Anlagen.
4. **Regeltreue steht auf einer Kennzahl.** Folge des Korrelations-Gates.
5. **Die fünfte Achse ist vorläufig** und belohnt noch Profit.

6. **Die Peer-Schwelle von 30 Prozent** liegt am Rand des stabilen Bereichs.
7. **Überlebensverzerrung.** Verwendet wird die heutige Indexzusammensetzung für die Jahre 2011–2023. Firmen, die seither ausgeschieden sind, fehlen — tendenziell die schlechter laufenden. Die Indexhistorie ist frei verfügbar; der Fix ist ein halber Tag.
8. **Keine Vorhersagevalidierung.** Ob der Score künftige Verstöße, Unfälle oder Strafen vorhersagt, ist nicht geprüft. Dafür fehlt eine Zielgröße mit ausreichendem zeitlichen Abstand.
9. **US-Bias.** Auslandsanlagen amerikanischer Konzerne fehlen, ebenso alle Anlagen unter der Meldeschwelle von 25 000 t.
10. **Materialität nur für Firmen mit Anlagendaten.** Für Banken und Software existiert keine Themenzuordnung.

16.1 Was als Nächstes den größten Unterschied macht

Maßnahme	Aufwand	Wirkung
Zehnjahreshistorie für den Tragfähigkeitsindex	Stunden	behebt Punkt 5
Indexhistorie rekonstruieren	halber Tag	behebt Punkt 7
Fehlerbalken aus CEMS-Messqualität ableiten	1 Tag	behebt Punkt 2
20 Firmen von Hand gegen Selbstauskunft prüfen	halber Tag	einzigste direkte Prüfung der Zuordnung
Scope-2-Daten ab SB 253	offen	größte inhaltliche Lücke

17 Aufbau und Reproduktion

17.1 Pipeline

Skript	Funktion
f01_sources.py	Sechs EPA-Direktmittenten-Blätter, E/S/I-Audit, vier Matching-Schwellen, zwei Zurechnungsregeln, CEMS-Messqualität
f02_features.py	Entkorrelierte Kennzahlen mit Fehlerbalken, k-Means-Profilgruppen, acht Datenvarianten
f03_simulation.py	Kombinationsraum, Monte Carlo, exakte ANOVA
f04_results.py	Rangbänder, zwei Listen, Aggregations-, Imputations-, Vintage- und Größentest
f06_new_sources.py	TRI-Giftstoffe, EIA-Erzeugung, OSHA-Unfallraten
f09_materiality.py	Materialitätsprofil aus NAICS-Tätigkeitsmix, Messlücke je Gruppe
f13_dashboard_data.py	Achsenbänder, Offenlegungsbilanz, Ledger je Firma
f14_viability.py	Fünfte Achse, Manipulationsresistenz, Fünf-Achsen-Korrelation
f15_silence_test.py	Schweigen-als-Signal-Test, Kosten des Schweigens
f17_experiments.py	Zehn Falsifikationsexperimente
f18_portfolio.py	PAB-Portfolio je Achse, Tilt-Sensitivität

17.2 Determinismus und Skalierung

Alle Zufallsprozesse laufen über einen festen Startwert (20260912). Gesamtlaufzeit unter zehn Minuten.

Die Tabelle der einzelnen Ziehungen wird bewusst nicht materialisiert: Bei 147 Firmen $\times$ 17 Kennzahlen $\times$ mehreren zehntausend Ziehungen wären das dreistellige Millionenzeilen. Stattdessen wird je Konfiguration vektorisiert im Arbeitsspeicher gerechnet und nur die Perzentilmatrix aufbewahrt.

17.3 Ausgabe

Ein eigenständiges HTML-Dashboard (`dashboard.html`) mit sieben Ansichten: Firma, Rangliste, Vergleich, Portfolio, Muster, nicht bewertbar, Methodik. Keine externen Abhängigkeiten, läuft per Doppelklick ohne Internet.

Was dieser Bericht nicht behauptet. Er stellt nicht fest, dass eine bestimmte Firma täuscht. Er trifft keine Aussage über Firmen ohne Anlagendaten. Er misst Scope 1 und nennt das eine Eingrenzung, keine Vollständigkeit. Und er gibt keine Rangplätze aus, wo die Daten nur Bänder hergeben.

Datenquellen. US EPA (GHGRP, Unit & Fuel Data, TRI, ECHO), OSHA Injury Tracking Application, US Department of Labor Wage & Hour Division, SEC-Pflichtberichte, Science Based Targets initiative, World Benchmarking Alliance, EIA-923/860, S&P-500-Konstituentenliste.

Methodik. Nardo, Saisana, Saltelli, Tarantola et al. (2008), *OECD/JRC Handbook on Constructing Composite Indicators* — Berg, Kölbel & Rigobon (2022), *Aggregate Confusion*, *Review of Finance* 26(6) — Dye (1985), *Disclosure of Nonproprietary Information*, *Journal of Accounting Research* 23(1) — Khan, Serafeim & Yoon (2016), *Corporate Sustainability: First Evidence on Materiality*, *The Accounting Review* 91(6) — Andersson, Bolton & Samama (2016), *Hedging Climate Risk*, *Financial Analysts Journal* — EU-Verordnung 2019/2089.