

Die Datenlücke schließen

Was an kostenlosen Quellen wirklich zu holen ist –
jede einzeln am Endpunkt geprüft

ETHack 2026 – Recherchebericht, Folgebericht zur Ranking-Auswertung

Alle Abrufe: 12. September 2026

Zusammenfassung

Der vorige Bericht hat zwei Lücken beziffert: die Emissionsreihe endet 2023, und nur 157 der 503 Indexmitglieder sind überhaupt bewertbar – fast ausschließlich Schwerindustrie. Dieser Bericht durchsucht die freie Datenlandschaft nach Abhilfe und prüft jeden Kandidaten am echten Endpunkt statt in der Dokumentation. Ergebnis: **beide Lücken sind zu einem großen Teil schließbar**. Für die Zeit nach 2023 liefern zwei Wege Daten bis ins laufende Jahr 2026. Für die Abdeckung bringen zwei bisher übersehene Quellen zusammen 228 zusätzliche Firmen – darunter eine, die im vorigen Bericht noch als „nur mit Headless-Browser erreichbar“ eingeschätzt wurde und sich als direkter Excel-Download herausstellte. Außerdem fand sich eine maschinenlesbare Konzernstruktur aus SEC-Pflichtanlagen, die die handgepflegte Tochartabelle ersetzt: 916 290 Einträge für 478 der 500 Mütter. Vier geprüfte Kandidaten sind Sackgassen, und zwei brauchen einen kostenlosen Account. Abschnitt 8 nennt die Umsetzungsreihenfolge, Abschnitt 9 das, was du anlegen musst.

Prüfmethode. Kein Kandidat steht hier, weil er in einer Dokumentation erwähnt wird. Jeder wurde am 12. September 2026 aufgerufen; bei jedem steht, was tatsächlich zurückkam – einschließlich der Fälle, in denen das eine Fehlermeldung war.

Inhaltsverzeichnis

1	Ausgangslage	3
2	Die geprüfte Quellenlage	3
3	Lücke 1: die Zeit nach 2023	3
3.1	EPA CAMPD – ein anderer Meldeweg für dieselben Kraftwerke	3
3.2	PUDL – derselbe Datensatz ohne Schlüssel	4
4	Lücke 2: die Abdeckung	5
4.1	SBTi – die Fehleinschätzung aus dem vorigen Bericht	5
4.2	SEC-Volltextsuche – Selbstauskunft aus Pflichtberichten	5
4.3	Konzernstrukturen aus SEC-Pflichtanlagen	6
5	Was bald von selbst kommt	6

6	Was sich als Sackgasse erwies	6
7	Was das zusammen bedeutet	7
7.1	Die ehrliche Bilanz	9
8	Umsetzungsreihenfolge	9
9	Was du anlegen musst	10
10	Was offen bleibt	10

1 Ausgangslage

Aus dem vorigen Bericht, zur Erinnerung:

- **Zeitliche Lücke.** Die EPA hat das Berichtsjahr 2024 trotz Meldefrist Mai 2025 bis heute nicht veröffentlicht. Ab Geschäftsjahr 2024 gibt es keine Emissionsdaten auf Firmenebene.
- **Strukturelle Lücke.** 157 von 503 Firmen bewertbar. Versorger 90 %, Immobilien 10 %, Informationstechnologie 16 %. Die Rangliste misst faktisch, wer große Schornsteine betreibt.
- **Achse B unvollständig.** Zwei von sechs Greenwashing-Warnsignalen berechenbar. Das stärkste – die Lücke zwischen versprochenem und tatsächlichem Reduktionspfad – fehlte mangels Zieldaten ganz.

2 Die geprüfte Quellenlage

Tabelle 1. Alle geprüften Kandidaten, Stand 12.09.2026

Quelle	Liefert	bis FJ	Zugang	Prüfergebnis
EPA CAMPD	Scope 1, Kraftwerke, CEMS-gemessen	2026	Schlüssel	läuft; DEMO_KEY nur 10 Anfragen/Std.
PUDL auf Zenodo	EPA-CEMS-Spiegel 1995–2026	2026	frei	Public Domain, 4,5 GB Stundenwerte
PUDL SEC-Ex-21	Konzern-Tochter-Struktur	2026	frei	916 290 Einträge, 478 von 500 Müttern
SBTi-Excel	Zielstatus, Zwischenziele	2026	frei	direkter xlsx-Download, 15 605 Organisationen
SEC-Volltextsuche	selbstberichtete Mengen	2026	frei	215 Indexfirmen, Extraktion nötig
CARB SB 253	Scope 1+2, verpflichtend	2025	frei	Portal offen seit 01.09., Frist 10.11.2026
EIA API v2	Brennstoff je Kraftwerk	2026	Schlüssel	Gegenprobe zu CEMS
CDP offen	nur Städte und Regionen	2025	frei	nein – keine Firmendaten im offenen Portal
iShares/BlackRock	Fonds-Kennzahlen	2026	frei	nein – nur Fondsaggregate, keine Einzelwerte
TPI	Transitionsbewertung	2026	frei	nein – Lizenz untersagt automatisiertes Auslesen
Climate TRACE	Anlagen weltweit	2024	frei	nein – Feld Owners bleibt leer

3 Lücke 1: die Zeit nach 2023

3.1 EPA CAMPD – ein anderer Meldeweg für dieselben Kraftwerke

Das Treibhausgas-Meldeprogramm (GHGRP) und die Clean Air Markets Program Data (CAMPD) stammen beide von der EPA, haben aber nichts miteinander zu tun. GHGRP ist eine jährliche Selbstmeldung mit langem Veröffentlichungsvorlauf. CAMPD kommt aus der kontinuierlichen Emissionsmessung am Schornstein, wird quartalsweise veröffentlicht und hat zwei bis drei Monate Verzug.




Abbildung 1. Wie weit jede Quelle zeitlich reicht. Orange markiert die eine, die einen Schlüssel verlangt.

Der Abruf am 12. September 2026 lieferte für die Jahre 2024, 2025 und 2026 Datensätze – rund 4000 Blockjahre je Jahr. Die zeitliche Lücke existiert für den Stromsektor schlicht nicht.

Zwei Eigenschaften machen CAMPD über die Aktualität hinaus wertvoll:

1. **Gemessen statt gerechnet.** CEMS misst am Schornstein. GHGRP-Werte werden überwiegend aus Brennstoffmengen hochgerechnet.
2. **Eigentümer und Betreiber getrennt.** Das Feld `ownerOperator` sieht so aus:

Alabama Power Company (Owner)|Alabama Power Company (Operator)

Damit lässt sich die Zurechnung nach Equity Share und nach operativer Kontrolle rechnen. Das war Schwachstelle 9 des vorigen Berichts: eine Ermessensentscheidung, die unsichtbar im Code steckte. Sie wird jetzt zu einer weiteren Dimension der Unsicherheitsanalyse.

Einschränkung, und zwar eine harte. CAMPD deckt nur Anlagen der Emissionshandelsprogramme ab – praktisch also Stromerzeugung. Raffinerien, Zementwerke, Stahl und Chemie erscheinen nicht. Für diese Branchen bleibt es bei 2023, bis die EPA das Berichtsjahr 2024 veröffentlicht.

3.2 PUDL – derselbe Datensatz ohne Schlüssel

Die Catalyst Cooperative veröffentlicht unter dem Namen PUDL aufbereitete US-Energiedaten auf Zenodo. Der Datensatz *PUDL Raw EPA Hourly CEMS* (zuletzt 6. September 2026) enthält die Stundenwerte von 1995 bis 2026, als Public Domain, ohne Anmeldung. 4,5 GB für die Stundenreihe, dazu kleinere Tabellen mit den Zuordnungen zwischen EPA- und EIA-Kennungen sowie Eigentumsanteilen aus dem EIA-Formular 860.

Damit gibt es für dieselbe Datengrundlage zwei Wege: den bequemen über die API mit Schlüssel und den schlüsselfreien über Zenodo mit mehr Rechenarbeit. Für einen Hackathon ist der erste richtig, für einen unbeaufsichtigt laufenden Dienst der zweite.

4 Lücke 2: die Abdeckung

4.1 SBTi – die Fehleinschätzung aus dem vorigen Bericht

Im vorigen Bericht stand, die Science Based Targets initiative habe kein öffentliches API, man müsse die Dashboard-Seite mit einem Headless-Browser abgreifen, Aufwand zwei bis drei Stunden. Das war falsch. Der Pfad `/download/excel` leitet auf eine veröffentlichte Tabelle weiter und liefert den vollständigen Datensatz:

```
https://sciencebasedtargets.org/download/excel  
→ 302 → xlsx, 2,3 MB, 15 605 Zeilen, 22 Spalten
```

Enthalten sind `company_name`, `isin`, `lei`, Sektor, und je Organisation der Status von Nahziel, Langfristziel und Netto-null-Ziel samt Zieljahren und Klassifizierung (1,5 Grad, deutlich unter 2 Grad, 2 Grad).

Tabelle 2. Was der SBTi-Datensatz für den S&P 500 hergibt (Abgleich über normalisierte Firmennamen)

Indexfirmen mit SBTi-Eintrag	241 von 503 (48 %)
davon mit geprüftem Nahziel	209
davon mit ausgewiesenem Zwischenzieljahr	209
davon mit zurückgezogener Zusage	50
Firmen, die heute <i>keine</i> Emissionsdaten haben	173

Damit werden drei der sechs Greenwashing-Warnsignale berechenbar, die bisher fehlten: das Vorhandensein von Zwischenzielen, die wissenschaftliche Prüfung des Ziels, und – neu und im vorigen Bericht gar nicht vorgesehen – der Rückzug einer einmal gegebenen Zusage.

Das interessanteste Feld im ganzen Datensatz ist `Commitment removed`. 50 Indexfirmen haben sich ein Klimaziel gesetzt und es später zurückgezogen. Das ist kein Indiz, das man aus Textanalyse ableiten müsste, sondern eine protokollierte Tatsache mit Datum. Als Glaubwürdigkeitssignal ist es schwer wegzudiskutieren.

4.2 SEC-Volltextsuche – Selbstauskunft aus Pflichtberichten

Die Volltextsuche der SEC (`efits.sec.gov`) ist ohne Anmeldung abrufbar und liefert strukturiertes JSON mit CIK je Treffer. Eine Suche nach `SScope 1` in 10-K-Berichten seit Januar 2025 ergibt 787 Dokumente, davon 131 von Indexmitgliedern. Über drei Suchbegriffe zusammengekommen: 215 Indexfirmen, davon 124 ohne heutige Emissionsdaten.

Entscheidend ist aber nicht, wie viele Firmen das Wort nennen, sondern bei wie vielen sich eine Zahl herausziehen lässt. Eine erste Stichprobe mit einem naiven Muster fand nur bei einer von sechs Firmen etwas – die meisten Nennungen stehen in Risikohinweisen („Vorschriften könnten uns verpflichten, Scope-1-Emissionen zu melden“), nicht in Offenlegungen. Mit drei verbesserten Mustern stieg die Ausbeute an einer Stichprobe von 40 Firmen auf **80 %**.

Was diese 80 % sind und was nicht. Gemessen wurde, ob in der Nähe von „Scope 1“ eine Zahl mit Mengeneinheit steht. Ob diese Zahl die gesuchte Gesamtmenge ist – und nicht ein Zieljahr, ein Prozentsatz oder der Scope-2-Wert –, ist damit *nicht* geprüft. Die Trefferquote ist eine Obergrenze für die Ausbeute und sagt nichts über die Genauigkeit. Vor dem Produktiveinsatz braucht es eine Stichprobe von etwa 20 handgeprüften Firmen.

4.3 Konzernstrukturen aus SEC-Pflichtanlagen

Die im vorigen Bericht am meisten kritisierte Stelle war die handgepflegte Tochter-Konzern-Tabelle mit rund 280 Einträgen: „Handarbeit und damit die am wenigsten skalierbare Stelle der ganzen Pipeline“.

Jedes 10-K enthält als Anlage 21 die Liste der Tochtergesellschaften. PUDL hat diese Anlagen für alle Einreichungen ausgewertet und als Tabelle veröffentlicht:

Tabelle 3. `core_sec10k__quarterly_exhibit_21_company_ownership`, gefiltert auf S&P-500-Mütter

Tochtereinträge insgesamt	3 800 706
davon unter S&P-500-Müttern	916 290
abgedeckte Mütter	478 von 500
Einträge mit Beteiligungsquote	99 117

Die Stichprobe bestätigt die Qualität: Southern Company führt 240 Töchter, darunter Alabama Power und Georgia Power; NextEra führt Florida Power & Light; Berkshire Hathaway führt MidAmerican Energy und Kern River Gas Transmission. Das sind genau die Zuordnungen, die bisher von Hand eingetragen wurden – hier stehen sie aus der Pflichtanlage einer Börsenaufsicht.

5 Was bald von selbst kommt

Kalifornien hat mit SB 253 eine Offenlegungspflicht beschlossen, die jede Firma mit mehr als einer Milliarde Dollar Umsatz und Geschäft in Kalifornien betrifft – praktisch also den gesamten S&P 500. Der Stand:

- Die Durchführungsverordnung wurde am 26. Februar 2026 von der kalifornischen Umweltbehörde beschlossen.
- Die ursprüngliche Frist zum 10. August 2026 wurde am 24. Juni auf den **10. November 2026** verschoben.
- Seit dem 1. September 2026 ist eine Einreichungsplattform offen.
- Die eingereichten Berichte werden über ein öffentliches Register zugänglich gemacht.
- Scope 1 und 2 ab 2026, **Scope 3 ab 2027**.

Das ist die strukturelle Lösung, nicht nur ein Notbehelf. Wenn diese Pflicht greift, existiert erstmals eine geprüfte, verpflichtende und kostenlose Scope-1-und-2-Quelle für nahezu den gesamten Index – und ab 2027 auch für Scope 3, also für genau den Teil, den heute keine freie Quelle abdeckt. Für dieses Hackathon-Wochenende kommt sie zwei Monate zu spät. Für die Architektur heißt das: einen `CarbSb253Source`-Platzhalter vorsehen, damit die Umstellung später ein Connector und keine Neuentwicklung ist.

6 Was sich als Sackgasse erwies

Diese vier wurden geprüft und bringen nichts – das gehört genauso dokumentiert wie die Treffer.

CDP. Es gibt tatsächlich ein offenes Datenportal unter `data.cdp.net`, und es antwortet. Es enthält 40 Datensätze – alle über Städte, Bundesstaaten und Regionen. *Firmendaten sind nicht*

darunter. Die Aussage des Ausgangspapiers, der beste Datensatz liege hinter einer Bezahlschranke, bestätigt sich; der offene Teil betrifft ein anderes Messobjekt.

BlackRock und iShares. Die Fondsseiten veröffentlichen Bestandslisten und Nachhaltigkeitskennzahlen. Die Kennzahlen sind jedoch *Fondsaggregate* – eine gewichtete durchschnittliche Kohlenstoffintensität für den ganzen Fonds, geliefert von MSCI. Einzelwerte je Unternehmen stehen nicht darin. Für eine Rangliste der Einzelfirmen ist das wertlos; für eine spätere Portfolio-Gegenprobe ist es als Vergleichszahl brauchbar.

Transition Pathway Initiative. Fachlich die beste freie Bewertung, die gefunden wurde, und sie deckt auch Banken und Immobilien ab. Aber die Nutzungsbedingungen der LSE sind eindeutig: Der Einsatz „automatisierter Werkzeuge (einschließlich Bots, Scraper oder Spider), um die Daten abzurufen, zu extrahieren oder zu indizieren“ ist genehmigungspflichtig. Ebenso die „Erstellung eines Index oder Fonds“ auf Basis dieser Daten – also genau die Bonusaufgabe der Challenge. Manuelle Einsicht zur Validierung ist erlaubt, eine Einbindung in die Pipeline nicht.

Climate TRACE. Wie im vorigen Bericht: Die API läuft, aber das Feld **Owners** kommt leer zurück. Ohne Eigentümerzuordnung sind Anlagendaten für ein Firmenranking nicht verwendbar.

7 Was das zusammen bedeutet




Abbildung 2. Abdeckung je GICS-Sektor, heute gegen erreichbar mit den neuen Quellen.

Die Komplementarität in Abbildung 3 ist kein Zufall. Die EPA erfasst, wer Schornsteine betreibt. Die SBTi erfasst, wer sich freiwillig ein Ziel gesetzt hat – und das tun bevorzugt Firmen mit geringem physischem Fußabdruck und hoher Markenempfindlichkeit. Energie: 0 % SBTi-Abdeckung bei 76 % EPA-Abdeckung. Informationstechnologie: 68 % SBTi bei 16 % EPA.

Die beiden Quellen sind fast spiegelbildlich




Abbildung 3. EPA-Anlagendaten und SBTi-Ziele decken gegenläufige Hälften des Index ab. Die gestrichelte Linie markiert, wo sich beide Anteile zu 100 ergänzen würden.

Abdeckung ist nicht gleich Abdeckung




Abbildung 4. Die 503 Indexmitglieder nach Art der verfügbaren Daten.

7.1 Die ehrliche Bilanz

Eine Gesamtzahl von „385 Firmen mit mindestens einer Quelle“ wäre genau die aufgeblasene Kennzahl, die der vorige Bericht kritisiert hat. Die Quellen liefern nicht dasselbe:

Tabelle 4. Abdeckung nach Art der Daten

Art	Firmen	Herkunft
gemessene Tonnen	157	EPA-Anlagendaten, wie bisher
selbstberichtete Tonnen, noch zu extrahieren	99	SEC-Volltext, 80 % Ausbeute angesetzt
nur Zielstatus, keine Menge	104	SBTi ohne Emissionsquelle
weiterhin ohne Daten	143	–
mit einer Emissionsmenge	256	51 % des Index
mit irgendeiner Information	385	77 % des Index

Die belastbare Zahl ist 256, nicht 385. Eine Kernnote braucht eine Menge. SBTi liefert keine – der Zielstatus gehört auf Achse B und darf die Abdeckung der Kernnote nicht schönrechnen. Und die 99 selbstberichteten sind eine Erwartung auf Basis einer Stichprobe von 40 Firmen, keine gezählten Werte. Belastbar ist heute: 157 gemessen, ein plausibler Aufwuchs auf rund 256, und 143 Firmen, für die es weiterhin nichts gibt.

8 Umsetzungsreihenfolge

Sortiert nach Wirkung je Aufwand. Die ersten drei sind für ein Hackathon-Wochenende realistisch.

S1 – SBTi einbinden (Aufwand: erledigt). Der Connector ist geschrieben und der Datensatz liegt im Cache. Es fehlt der Abgleich über ISIN statt über Firmennamen, was die heutigen 48 % Trefferquote noch anheben dürfte. Bringt: drei Greenwashing-Signale und 173 Firmen auf Achse B. *Höchste Wirkung, geringster Restaufwand.*

S2 – CAMPD für Periode B (Aufwand: zwei Stunden nach Schlüsselerhalt). Connector ist geschrieben. Sobald der Schlüssel da ist: Daten für 2024 bis 2026 ziehen, über `ownerOperator` zuordnen, und den Stromsektor damit bis ins laufende Jahr fortschreiben. Für alle anderen Branchen bleibt die Kennzeichnung „Stand 2023“. Das ist ein ehrlicheres Ergebnis als eine einheitliche Fortschreibung.

S3 – Tochartabelle durch Exhibit 21 ersetzen (Aufwand: ein halber Tag). Die 916 290 Einträge über die Mutter-CIK anbinden, gegen die heutige Handtabelle validieren, Abweichungen prüfen. Beseitigt die am wenigsten skalierbare Stelle der Pipeline und dürfte die Zuordnungsquote über die heutigen 48 % der Emissionen heben.

S4 – Equity Share gegen operative Kontrolle (Aufwand: eine Stunde). Mit dem getrennten Eigentümer- und Betreiberfeld beide Zurechnungsregeln rechnen und als weitere Dimension in die Unsicherheitsanalyse geben. Schließt Schwachstelle 9 des vorigen Berichts.

S5 – SEC-Volltextextraktion (Aufwand: ein bis zwei Tage). Die aufwendigste Position, und die einzige, die die Abdeckung wirklich erhöht. Reihenfolge: Muster verfeinern, an 20 handgeprüften Firmen die Genauigkeit messen, erst dann in die Pipeline aufnehmen – und jeden

extrahierten Wert als „selbstberichtet, unbestätigt“ kennzeichnen, getrennt von den gemessenen EPA-Werten.

S6 – Platzhalter für SB 253 (Aufwand: eine Stunde). Einen CarbSb253Source anlegen, der heute nichts liefert, und die Feldnamen nach dem CARB-Meldeschema benennen. Wenn im November die Berichte kommen, ist das ein Connector und keine Neuentwicklung.

S7 – EIA als Gegenprobe (Aufwand: ein halber Tag). Aus den Brennstoffmengen des EIA-Formulars 923 lassen sich Emissionen mit Standardfaktoren nachrechnen. Wo CEMS und EIA weit auseinanderliegen, stimmt etwas nicht. Das ist die einzige verfügbare unabhängige Kontrolle der Zurechnung – und damit wertvoller, als es nach Fleißarbeit aussieht.

9 Was du anlegen musst

Tabelle 5. Benötigte Zugänge – beide kostenlos und sofort

Dienst	Registrierung	Wofür
EPA CAM API	https://www.epa.gov/power-sector/cam-api-portal	Wichtigster Punkt. Schließt die Periode-B-Lücke für den Stromsektor. Ohne Schlüssel greift DEMO_KEY mit 10 Anfragen je Stunde – für einen Testlauf genug, für den Betrieb nicht.
EIA Open Data	https://www.eia.gov/opendata/register.php	Gegenprobe über Brennstoffmengen (S7). Nachrangig.

Den Schlüssel setzt du als Umgebungsvariable, der Connector liest sie selbst:

```
export EPA_CAMD_API_KEY="..."
.venv/bin/python scripts/01_fetch.py campd_emission campd_facility
```

Alles andere in diesem Bericht läuft ohne Anmeldung. Kaggle wird nicht mehr gebraucht – der dort kursierende ESG-Snapshot war ohnehin nur Vergleichsmaßstab und ist durch SBTi als Achse-B-Quelle abgelöst.

10 Was offen bleibt

- **Scope 2 und Scope 3 bleiben ungelöst** bis SB 253 greift. Keine der geprüften freien Quellen liefert sie flächendeckend. Die Selbstauskunft aus 10-K-Berichten enthält teilweise Scope-2-Angaben, aber unsystematisch.
- **143 Firmen bleiben ohne jede Information**, überwiegend Finanzdienstleister und Kommunikation. Für sie ist die ehrliche Ausgabe „nicht bewertbar“ und keine Schätzung.
- **Die SBTi-Abdeckung ist selbstselektiert.** Firmen melden sich freiwillig. Dass die Energiebranche zu 0 % vertreten ist, ist selbst eine Information – aber keine, die man als Bewertung verrechnen darf.
- **Die 80 % Extraktionsausbeute sind ungeprüft** in der Genauigkeit. Bis eine Handstichprobe vorliegt, ist jede darauf gestützte Abdeckungszahl eine Erwartung, keine Messung.

Der Satz, der sich seit dem vorigen Bericht geändert hat. Dort stand: „Für Scope 2 und Scope 3 existiert keine kostenlose Vollabdeckung der 500 Firmen. Das ist keine Lücke, die man mit mehr Fleiß schließt.“ Das gilt weiterhin für Scope 2 und 3. Für Scope 1 und für die Zeit nach 2023 gilt es nicht mehr: Dort war die Lücke tatsächlich eine Frage des Suchens.