

Warum die Daten Fehler enthielten

Ursachen, Reparaturen und ein Prüfablauf, der Menschen nur Grenzfälle vorlegt

ETHack 2026 – Folgebericht zum Verbesserungsbericht

13. September 2026

Zusammenfassung

Der Verbesserungsbericht hat 380 auffällige Werte beschrieben. Dieser Bericht fragt, *warum* sie entstehen, prüft jede Vermutung an den Rohdaten und an der Dokumentation der Quellen, und repariert die Ursachen. Das Ergebnis ist unbequem und hilfreich zugleich: Fast nichts davon ist ein Tippfehler in einer Quelle. Die Fehler entstehen an wenigen Stellen, an denen die Pipeline eine Quelle anders liest, als sie gemeint ist – eine Null, die „nicht gemeldet“ heißt; ein Messprogramm, das CO₂ gar nicht erfasst; eine Anlage, die beim Zusammenführen doppelt zählt; eine Tochterfirma, die zum falschen Jahr gehört; ein Firmenname, der als Wortanfang eines fremden Namens steckt. Zwei Diagnosen des Verbesserungsberichts halten der Prüfung nicht stand: Die CAMPD-Nullen sind keine Fehlzuordnungen, und die ECHO-Werte über 12 sind keine falsch gezählten Programme, sondern doppelt verbundene Zeilen. Nach der Reparatur finden dieselben Regeln statt 382 nur noch 18 Fälle, und an Menschen gehen statt 246 genau 5. Zehn Kontrollfälle mit belegter Antwort prüfen bei jedem Lauf, dass die Reparaturen halten – alle 11 bestehen. Die schärfste Konsequenz steht in Abschnitt 3: Der Datensatz enthält nur noch Werte, die eine Quelle veröffentlicht hat – entweder für die Firma selbst oder als Summe ihrer Anlagen. Jede Kennzahl, die *wir* gerechnet hatten – Intensität je Umsatz, Tonnen je MWh, Unfallrate, Trends, Rangbänder –, ist entfernt. Sie war der eigentliche Grund für die selbstgesetzten Schwellen, mit denen wir die eigenen Zahlen anschließend wieder einfangen mussten. Die Lehre für den KI-Einsatz ist ähnlich unbequem: Ein Sprachmodell, das jeden Einzelfall begutachtet, ist die teure Antwort auf eine Frage, die man meist im Code beantworten kann.

Inhaltsverzeichnis

1	Was geprüft wurde	3
2	Warum die Fehler entstehen	3
2.1	Eine Null, die „nicht gemeldet“ heißt	4
2.2	Ein Programm, das die Größe nicht misst	4
2.3	Zusammenführen, das Zeilen vervielfacht	4
2.4	Eine Quelle, die ihre Angaben nicht prüft	4
2.5	Namen statt Kennungen	5
2.6	Zeit, die nicht mitgeführt wird	5
2.7	Definitionen, die zusammengeworfen werden	5
3	Nur was eine Quelle veröffentlicht	6
4	Was repariert wurde	6

5	Wie man KI wirksam einbaut	8
5.1	Wo KI hilft – und wo nicht	8
5.2	Der Aufbau	8
5.3	Warum die Konfidenz des Modells nicht reicht	8
6	Wo der Mensch gebraucht wird	9
7	Ergebnisse dieses Laufs	9
7.1	Reparatur-Kontrolle	10
7.2	Drei Durchgänge mit dem Modell – und was sie gezeigt haben	10
8	Grenzen und nächste Schritte	11

1 Was geprüft wurde

Grundlage sind der gesammelte Datensatz (`dataset_long.parquet`), die Firmen-Zwischentabellen und – anders als beim Verbesserungsbericht – die Rohdaten aller Quellen im Zwischenspeicher. Jede Ursache in Abschnitt 2 ist an mindestens einem konkreten Fall in den Rohdaten nachgesehen und, wo es um die Bedeutung eines Feldes geht, an der Dokumentation der Quelle belegt.

Regel	Befund	vorher	heute	Reparatur
F01	Zwei Ticker teilen eine CIK: Konzernwerte doppelt	3	0	CIK-Deduplizierung in <code>consolidate.py</code>
F02	Exakt 0 t trotz zugeordneter Anlage	83	0	fehlend statt 0 in <code>canonical.py</code>
F03	0 t CO2, Programm verlangt kein CO2	99	0	CO2 nur aus ARP, RGGI, NSPS4T
F04	Mehr als 12 Verstoßquartale je Anlage	2	0	Join entdoppelt, nur V und S gezählt
F05	Mehr als 1,3 t CO2 je MWh	1	0	Grenze 1,3 t/MWh beim Export
F06	Stromrate eines Nicht-Versorgers	23	0	Rate nur für Kraftwerksflotten
F06	F06_egrid_zuordnung	0	1	–
F07	Trend oder Basisjahr durch Anlagenbasis verzerrt	7	0	Trend erst ab drei Jahren mit stabiler Basis
F08	Tochter vor oder ohne Konzernzugehörigkeit	20	0	Gültigkeitszeiträume in <code>resolve.py</code>
F09	Unfallrate auf unplausiblen Stunden	4	0	Stundennenner 200-4.000 je Beschäftigtem
F09	F09_osha_stunden_unplausibel	0	4	–
F10	Lohnverfahren nur über den Handelsnamen	0	7	bleibt: Franchise ist ein Grenzfall
F10	Lohnverfahren: Team-Zuordnung nicht nachvollziehbar	35	0	eigene Zuordnung statt Team-Datei
F11	Lohnverfahren ohne Nachzahlung und Betroffene	69	0	Verstöße und Bußgelder als eigene Kennzahlen
F12	SBTi: validiert und zurückgezogen vermischt	25	0	Status je Zieltyp getrennt
F13	SBTi: Zieljahr vorbei	4	0	abgelaufenes Ziel als eigene Kennzahl
P01	Extrem im Branchenvergleich	1	6	bleibt: echte Extreme sind kein Fehler
P02	Rangband breiter als 70 Punkte	6	0	ab Band 70 kein Median mehr

Von 382 Fällen bei 176 Firmen bleiben 18 bei 17 Firmen. Keiner davon hat mehr die Stufe *Fehler*: Was nachweisbar falsch war, ist repariert; was übrig ist, braucht einen Beleg, den die Daten nicht hergeben.

2 Warum die Fehler entstehen

Sieben Mechanismen erklären fast alles. Keiner davon ist ein Tippfehler in einer Quelle; fast alle entstehen an der Nahtstelle zwischen dem, was eine Quelle meint, und dem, was die Pipeline daraus liest.

2.1 Eine Null, die „nicht gemeldet“ heißt

Befund. 83 Firmenjahre stehen bei exakt 0 t CO₂, obwohl der Firma Anlagen zugeordnet sind. Kraft Heinz fällt von 45 412 t (2021) auf 0 (2022), mit denselben vier Anlagen.

Mechanismus. Die EPA-Tabelle führt eine Anlage weiter in den Stammdaten, auch wenn sie keine Menge mehr meldet. Die Pipeline summiert fehlende Mengen als 0. In den Rohdaten sind es 19 155 Anlagenjahre mit 0 t; bei 17 394 davon gibt es überhaupt keine gemeldete Menge – weder direkt noch geliefert – und bei 15 733 fehlt sogar der Anlagentyp. Eine regulatorische Erklärung liefert die Aussteigeregulierung 40 CFR 98.2(i): Wer fünf Jahre unter 25 000 t oder drei Jahre unter 15 000 t liegt, darf die Meldung einstellen [1]. Die Anlage verschwindet dann nicht aus dem Register, ihre Menge schon.

Folge. Eine Null in dieser Quelle bedeutet „nicht gemessen“, fast nie „emissionsfrei“. Wer sie als Zahl verrechnet, macht Firmen sauberer und erzeugt Trends, die nur das Meldeverhalten abbilden.

2.2 Ein Programm, das die Größe nicht misst

Befund. Marathon Petroleum, Valero, ADM und Merck stehen acht Jahre lang bei 0 t CO₂ gemessenen Kraftwerks-CO₂. Der Verbesserungsbericht vermutete Fehlzugeordnungen.

Mechanismus. Die Zuordnung stimmt – es sind echte Kessel und Turbinen dieser Firmen. Laut Programmfeld melden sie aber ausschließlich im Programm SIPNOX. Der Datenleitfaden der EPA nennt für SIPNOX „Heat input and NO_x emissions“, für RGGI dagegen „Heat input and CO₂ emissions“; CO₂ verlangen das Acid Rain Program, RGGI und NSPS4T [2]. Merck meldet 2,2 Millionen MWh Last bei 0 t CO₂ – die Last wird gemessen, das CO₂ nicht.

Korrektur am Verbesserungsbericht. Keine Fehlzugeordnung, sondern eine fehlende Messpflicht. Die richtige Reparatur ist nicht, die Anlagen zu verwerfen, sondern CO₂-Werte nur aus Programmen zu übernehmen, die CO₂ verlangen.

2.3 Zusammenführen, das Zeilen vervielfacht

Befund. Tesla: 24 Verstoßquartale je Anlage, Northrop Grumman 13,5. In drei Jahren sind höchstens 12 möglich.

Mechanismus. Die ECHO-Historie ist eine Zeichenkette mit genau 12 Zeichen, eines je Quartal: _ beanstandungsfrei, V Verstoß, S schwerer Verstoß, U ungeklärt, Leerzeichen ohne Daten. Tesla hat eine einzige Anlage mit SSSSSSSSSSSS. Beim Verbinden mit den EPA-Anlagen über die FRS-Kennung entstehen zwei Zeilen, weil die EPA für dieselbe Anlage zwei Schreibweisen des Konzernnamens führt. Aus 12 werden 24. Zusätzlich zählt die Pipeline U als Verstoß.

Korrektur am Verbesserungsbericht. Nicht Programme statt Quartale werden gezählt, sondern dieselbe Anlage zweimal. Die Reparatur ist ein Kardinalitätstest beim Verbinden: Eine Anlage darf nach dem Join genau einmal vorkommen.

2.4 Eine Quelle, die ihre Angaben nicht prüft

Befund. McDonald's hat eine Unfallrate von 21,2 – das Dreifache des Branchen-p99. Grundlage sind vier Meldungen mit im Median 50 Arbeitsstunden je Beschäftigtem im Jahr.

Mechanismus. Die Rate ist Fälle je Stunden. Wer die Stunden falsch einträgt, erzeugt jede beliebige Rate. OSHA schreibt dazu selbst: „OSHA also does not validate the counts of workers, hours, or injury and illness counts“ und „concluding that establishments are the most dangerous or the

least dangerous solely based on whether they have the highest or lowest rates from these data would be inappropriate“ [3]. Über alle Meldungen melden 9 749 Betriebe mehr als 8 760 Stunden je Beschäftigtem – mehr, als ein Jahr Stunden hat – und 18 774 weniger als 200.

2.5 Namen statt Kennungen

Befund. Die Team-Datei nennt für Air Products 212 Lohnverfahren. In den Rohdaten des Arbeitsministeriums gibt es für Air Products keinen einzigen Fall – aber 15 Fälle von „APDC Cleaning Services“.

Mechanismus. Die Lohnverfahren tragen keine Firmenkennung, nur Rechts- und Handelsnamen, oft mit Filialzusatz. Ein Abgleich über Namensbestandteile findet das Börsenkürzel „APD“ in einem fremden Firmennamen. Dasselbe Muster zeigte sich bei der eigenen Zuordnung: US Steel wurde zu Steel Dynamics, Talen Energy zu Vistra (10,5 Mt 2023, noch im Bestand). Die Forschung zu Entity Matching kommt zu einem ähnlichen Bild: Regelbasierte Verfahren neigen zum Übermatching; auf 755 540 von Fachleuten gelabelten Paaren erreichen Regeln 91,3 % F1, ein großes Sprachmodell 99,0 % [4].

Derselbe Mechanismus im eigenen Code. Die Tochtertabelle wurde auch als Wortanfang geprüft, damit „Georgia Power Services“ bei Georgia Power landet. Ohne Wortgrenze zieht „linde“ aber die *Linden Generating Station* an sich: 4,7 TWh fremder Strom bei Linde, dazu ein Kraftwerk bei KLA. Beide standen als Stromrate im Datensatz. Ein Leerzeichen in der Bedingung – Treffer nur bei “linde” oder “linde ...” – beendet die ganze Fehlerklasse.

2.6 Zeit, die nicht mitgeführt wird

Befund. PPL wächst angeblich um 240 % im Jahr. Constellation hat 2019 bis 2021 exakt 0 t. WestRock erscheint 2023 unter Smurfit Westrock, Pioneer unter ExxonMobil.

Mechanismus. Die Indexliste kennt nur den heutigen Stand, die Tochtertabelle kennt keine Gültigkeitszeiträume. PPL hat 2018 genau eine zugeordnete Anlage mit 5 kt, ab 2019 neun Anlagen mit 28 Mt – die Zuordnung springt, nicht die Emission. Konzernumbauten (Exelon-Abspaltung 2022, WestRock-Fusion Juli 2024, Pioneer-Übernahme Mai 2024) werden rückwirkend auf alle Jahre projiziert.

2.7 Definitionen, die zusammengeworfen werden

Befund. 25 Indexfirmen sind bei SBTi „validiert“ und „Zusage zurückgezogen“ zugleich. GE hat 4,44 t CO₂ je MWh. Alphabet, Fox und News Corp stehen je zweimal im Datensatz.

Mechanismus. SBTi führt Status je Zieltyp; „Commitment removed“ heißt, dass ein Ziel nicht binnen 24 Monaten eingereicht wurde [5]. Ein gesetztes Nahziel und eine zurückgezogene Netto-null-Zusage sind kein Widerspruch – die Kennzahl wirft beides zusammen. Die Stromrate eines Heizkraftwerks ist keine Aussage über den Konzern. Und Aktiengattungen mit gemeinsamer CIK sind ein Emittent, nicht zwei.

Mechanismus	Wo es auftritt	Gegenmittel
Null heißt nicht gemeldet	EPA GHGRP	fehlend statt 0; Off-Ramp als eigener Status
Programm misst Größe nicht	CAMPD	CO ₂ nur aus ARP, RGGI, NSPS4T
Join vervielfacht	ECHO ↔ GHGRP	Kardinalitätstest nach jedem Join
Quelle prüft nicht	OSHA ITA	Nenner-Plausibilität je Meldung vor der Aggregation
Namen statt Kennungen	WHD, GHGRP, CAMPD	CIK, LEI (GLEIF, CC0), EIA-860; KI-Gutachten für Grenzfälle
Zeit nicht mitgeführt	Tochertabelle, Indexliste	Gültigkeit von-bis; historische Indexliste
Definitionen vermischt	SBTi, eGRID, CIK	Status je Zieltyp; Kennzahl nur für passende Branche; CIK-Deduplizierung

3 Nur was eine Quelle veröffentlicht

Die Reparaturen in Abschnitt 4 haben eine Gemeinsamkeit, die erst im Rückblick auffällt: Fast jede selbstgesetzte Schwelle – 200 bis 4000 Stunden je Beschäftigtem, drei Kraftwerke und eine Terawattstunde, Basisquote zwischen 0,2 und 2,5, höchstens 1,3 t CO₂ je MWh – war nötig, um eine Zahl einzufangen, *die wir selbst gerechnet hatten*. Keine Quelle veröffentlicht eine Unfallrate je 100 Vollzeitkräfte für McDonald’s, eine CO₂-Intensität je Umsatz für PPL oder eine Tonne je MWh für General Electric. Diese Zahlen entstanden erst bei uns – und mit ihnen die Notwendigkeit, sie zu verteidigen.

Die Regel lautet jetzt: Entweder eine vertrauenswürdige Quelle veröffentlicht den Wert – oder es gibt keinen Wert. Jede Zeile im Datensatz trägt dafür das Feld `wert_art` mit genau zwei erlaubten Ausprägungen:

- **gemeldet** – die Quelle veröffentlicht genau diese Zahl für genau diese Firma (SEC-Umsatz, SBTi-Status, WBA-Note).
- **aggregiert** – Summe oder Anzahl der von der Quelle veröffentlichten Einzelwerte über die Anlagen oder Betriebe der Firma. Addition, mehr nicht.

Eine dritte Ausprägung ist nicht zugelassen; der Export bricht ab, wenn eine auftaucht.

Was dadurch verschwunden ist. Elf Kennzahlen: CO₂-Intensität, Tonnen je MWh, Unfallrate DART, Verstoßquartale je Anlage, beide Trends, Basisjahr-Quote, Intensitäts-Illusion, Zuordnungskonfidenz und die drei Rangband-Werte. Der Datensatz hat 44 statt 50 Kennzahlen und 11 425 statt 11 819 Zeilen.

Was an ihre Stelle tritt. Zähler und Nenner stehen jetzt einzeln da, beide von der Quelle: eGRID-Menge *und* Nettoerzeugung, OSHA-Fälle *und* gemeldete Arbeitsstunden *und* Betriebsstätten, ECHO-Quartale *und* Anlagenzahl, Scope-1-Tonnen *und* Umsatz *und* Anlagenzahl. Wer eine Rate braucht, bildet sie selbst – und sieht dabei, woraus.

Was das kostet. Die Analyse (Monte-Carlo-Rangbänder, Intensitäten, Trends) rechnet weiter, aber sie ist Analyse und steht im Bericht, nicht im Datensatz. In der Belastbarkeitsansicht fallen dadurch die Familien „Emissionstrend“ und „Greenwashing-Signale“ weg: In allen drei Bereichen belastbar sind noch 16 statt 42 Firmen, und keine Branche erreicht mehr sechs solcher Firmen. Das ist kein Rückschritt in der Datenlage, sondern deren ehrliche Anzeige – die 42 beruhten zu einem Teil auf Kennzahlen, die wir selbst erzeugt hatten.

4 Was repariert wurde

KI war hier nicht der erste Hebel. Von 382 Fällen stammten über neun Zehntel aus Mechanismen, die man im Code abstellen kann – schneller, billiger und reproduzierbar als jedes Gutachten. Umgesetzt ist das in der Reihenfolge der Wirkung; die Spalte „vorher/heute“ in Abschnitt 1 zeigt, was jede

Reparatur gelöst hat.

1. **Fehlend ist nicht Null.** Wo die EPA keine Menge meldet, gibt es keinen Wert mehr (`canonical.py`). Das betrifft 19155 Anlagenjahre und löst 83 Fälle.
2. **Messpflicht als Datenfeld.** CO₂ kommt nur noch aus Programmen, die es verlangen: ARP, RGGI, NSPS4T (`consolidate.py`). 99 Fälle.
3. **Join entdoppeln, richtig zählen.** Eine Anlage kommt je Firma einmal vor, gezählt werden nur die Quartale mit V oder S – nicht jeder Großbuchstabe der Historie (`05b_firmenaggregate.py`). 639 doppelte Zeilen entfernt.
4. **Keine Rate aus ungeprüften Angaben.** Die Unfallrate DART ist ersatzlos entfallen – OSHA prüft weder Stunden noch Fallzahlen nach. Stattdessen stehen Fälle, Stunden und Betriebsstätten einzeln da; auffällige Stundenangaben (McDonald's: im Median 50 Stunden je Beschäftigtem) tragen einen Hinweis am Wert, werden aber nicht überschrieben.
5. **Wortgrenze bei Namen.** Die Tochtertabelle trifft nur noch an der Wortgrenze (`resolve.py`); die Lohnverfahren kommen aus den Rohdaten statt aus der Team-Datei. Air Products verliert 212 fremde Verfahren, Linde ein fremdes Kraftwerk.
6. **Gültigkeitszeiträume.** Jede strittige Zuordnung hat jetzt ein Von und ein Bis (`VALIDITY` in `resolve.py`): Talen gehört nie zu Vistra, WestRock erst ab 2024, Pioneer ab 2024, Exelon Generation bis 2021, danach Constellation.
7. **Anlagenzahl neben die Menge.** PPL 2018 bleibt im Datensatz – die Summe der gemeldeten Anlagenmengen ist richtig. Falsch war der Trend darauf, und Trends stehen nicht mehr im Datensatz. Die Anlagenzahl je Jahr steht daneben, damit jeder sieht, worauf die Summe beruht.
8. **Keine Stromrate.** Statt zu entscheiden, für wen eine selbstgerechnete Rate gilt, gibt es keine: eGRID meldet Menge und Nettoerzeugung je Kraftwerk, beide stehen als Summe da. Berkshire Hathaway behält 83 TWh und 56 Mt, GE behält sein Kraftwerk – die 4,44 t CO₂/MWh gab es nur bei uns.
9. **Definitionen trennen.** SBTi-Status je Zieltyp, abgelaufene Nahziele als eigene Kennzahl; Lohnverfahren getrennt nach Untersuchungen, festgestellten Verstößen, Nachzahlung und Bußgeld. Ein Verfahren ohne Nachzahlung ist damit kein Fehler mehr, sondern ein Befund.
10. **Ein Emittent, eine Zeile.** Aktiengattungen mit gemeinsamer CIK werden zusammengeführt, die zweite Gattung wird zum Alias (GOOG, FOX, NWS).
11. **Harte Grenzen beim Export.** `07_dataset.py` bricht ab bei: mehr als 12 Verstoßquartalen je Anlage, exakter Null in Mengen, doppelten Zeilen, doppelter CIK – und bei jedem Wert ohne belegte Herkunft.
12. **Flags reisen mit.** Was übrig bleibt, wird nicht gelöscht, sondern trägt `quality_status`, Regel und Begründung bis in die Oberfläche.

Kontrolle statt Vertrauen. Elf Fälle mit belegter Antwort laufen bei jedem Durchgang mit: KHC 2022 ohne Wert, MPC ohne CO₂-Menge, TSLA bei zwölf Quartalen auf einer Anlage, keine gerechnete Rate im Bestand, Berkshires Menge und Erzeugung weiterhin gemeldet, MCD mit Stunden statt Unfallrate, APD ohne fremde Lohnverfahren, PPL ohne Trendwert, Vistra ohne Talen, GOOG nicht mehr im Bestand – und die Kontrolle, dass jeder Wert im Bestand gemeldet oder aggregiert ist. Alle 11 von 11 bestehen (Abschnitt 7). Kommt eine Ursache zurück, fällt sie hier auf, nicht erst im Ranking.

5 Wie man KI wirksam einbaut

5.1 Wo KI hilft – und wo nicht

Regeln finden Kandidaten zuverlässig, können aber den Einzelfall nicht erklären. Genau dort liegt die Stärke eines Sprachmodells: aus einem Bündel von Belegen die wahrscheinlichste Ursache benennen. Ist „APDC Cleaning Services“ Air Products? Ist eine Stromrate bei Berkshire Hathaway ein Fehler oder echte Versorgertätigkeit? Ist ein Sprung von 5 kt auf 28 Mt Klimaschutz, ein Zukauf oder eine Lücke in der Zuordnung?

Nicht geeignet ist ein Modell dafür, fehlende Zahlen zu liefern, Konzernbeziehungen aus dem Gedächtnis zu behaupten oder allein über Werte zu entscheiden, von denen ein Ranking abhängt.

Die wichtigste Einsicht dieses Berichts. Ein Gutachten je Wert ist die teure Antwort auf eine Frage, die meist im Code steht. Von 382 Fällen waren 239 Stufe *Fehler* – und fast alle davon gingen auf zwölf Stellen im Code zurück. Nach der Reparatur begutachtet das Modell 18 Fälle statt 382, und die Kosten fallen von 323 000 auf 14 887 Tokens. KI gehört an das Ende der Kette, nicht an den Anfang: erst reparieren, dann prüfen, dann fragen.

5.2 Der Aufbau

1. **Regeln setzen die Schwere.** Das Modell kann einer Regel widersprechen, aber eine Regel-Stufe nicht selbst ändern.
2. **Belegpaket statt Frage.** Jeder Fall geht mit Wert, Zeitreihe, Branchenvergleich und Rohdaten-Auszug an das Modell. Die Anweisung verbietet, Firmenzahlen aus eigenem Wissen zu ergänzen, und verlangt, allgemeines Wissen zu kennzeichnen.
3. **Feste Antwortform.** Ein JSON-Schema erzwingt Urteil (fehler, plausibel, unklar), eine Ursache aus einer festen Liste, Handlungsvorschlag, Konfidenz und die Frage, ob ein Mensch nötig ist. „Unklar“ ist ausdrücklich eine gute Antwort.
4. **Weiterleitung durch eine Regel, nicht durch das Modell.** Unsichere Fälle (Konfidenz unter 0,6 oder „unklar“) gehen zuerst an ein stärkeres Modell, nicht an einen Menschen. Ein Mensch kommt nur in vier Fällen dran: Regel und KI widersprechen sich; das Modell bleibt auch nach der Eskalation unsicher; ein Eingriff träfe das Ranking oder mehr als eine Megatonne; das Modell verlangt Belege, die es nicht hat, *und* ist sich nicht sicher (unter 0,85).
5. **Zwischenspeicher.** Gleicher Fall, gleiche Anweisung, gleiches Modell ergibt dieselbe gespeicherte Antwort. Das macht den Lauf reproduzierbar und einen zweiten Lauf kostenlos.
6. **Kontrolle an belegten Fällen.** Zehn Fälle mit bekannter Antwort laufen bei jedem Durchgang mit. Sie messen heute nicht mehr das Modell, sondern die Reparaturen – das Modell kommt mit diesen Fällen gar nicht mehr in Berührung.

5.3 Warum die Konfidenz des Modells nicht reicht

Sprachmodelle als Gutachter sind systematisch zu sicher. Eine Untersuchung an 14 Modellen fand etwa für GPT-4o eine Genauigkeit von 49,7 % bei einem Kalibrierungsfehler von 39,3 % – die Antworten häufen sich bei 90 bis 100 % Konfidenz, die Trefferquote liegt weit darunter [9]. Zwei Gegenmittel sind belegt: mehrere Urteile zusammenführen, was Genauigkeit und Kalibrierung verbessert, und Schwellen nicht setzen, sondern an gelabelten Fällen kalibrieren. Ein aktueller Ansatz legt die Schwelle so fest, dass die Fehlerrate unter den angenommenen Urteilen mit hoher Wahrscheinlichkeit unter einer Vorgabe bleibt, holt bei Unsicherheit zusätzliche Belege und gibt sonst an Menschen ab [10].

Für dieses Projekt heißt das: Die Schwelle 0,6 ist ein Startwert, keine Kalibrierung. Sie wird erst belastbar, wenn die Referenzmenge wächst – idealerweise aus den Entscheidungen, die Menschen im Prüfablauf ohnehin treffen.

6 Wo der Mensch gebraucht wird

Ein Mensch ist teuer. Sein Einsatz lohnt sich dort, wo weder Regel noch Modell die Frage aus den vorhandenen Belegen beantworten können, oder wo ein Fehler viel kostet.

Grenzfall	Warum Regel und KI nicht reichen	Was der Mensch braucht
Stichtag eines Konzernumbaus	Das Modell kennt Übernahmen, aber nicht verlässlich das Vollzugsdatum	Pressemitteilung, 8-K-Meldung
Franchise oder eigener Betrieb	Aus dem Handelsnamen nicht entscheidbar	Franchise-Offenlegung (FDD), Adresse
Echter Extremwert oder Fehler	Vistra kann real kohlelastig sein – oder falsch zugeordnet	Anlagenliste, Geschäftsbericht
Regel und KI widersprechen sich	Einer von beiden irrt; das Muster ist lehrreich	beide Begründungen nebeneinander
Korrektur mit großer Wirkung	ab 1 Mt oder mit Einfluss auf das Ranking	Rohdaten-Auszug, Vorher-Nachher
Neue Quellendefinitionen	SBTi führt seit September 2026 neue Status ein	Definitionsdocument der Quelle
Lizenzfragen	Rechtliche Einordnung, nicht technische	Nutzungsbedingungen

Der Ablauf. Eine Entscheidung ist eine Zeile in `data/review/entscheidungen.csv` mit Flag, Entscheidung, Name, Datum und einem Satz Begründung. Beim nächsten Lauf hat sie Vorrang vor Regel und KI und fließt mit Namen in den Datensatz. Die Prüfliste in der Oberfläche sortiert nach Wirkung: rankingrelevant zuerst, dann nach Tonnen, dann nach Unsicherheit des Modells.

Der wichtigste Effekt ist der Rückfluss. Jede menschliche Entscheidung ist ein neuer Referenzfall für die Messung der KI – und jede wiederkehrende Entscheidung ein Kandidat für eine neue Regel. So wird der teure Schritt mit der Zeit seltener, ohne dass man ihm blind vertraut.

7 Ergebnisse dieses Laufs

	vor der Reparatur	heute
Kandidaten aus den Regeln	382	18
davon Stufe Fehler	239	0
betroffene Firmen	176	17
automatisch entschieden	136	13
an Menschen	246	5
Tokens für die KI-Prüfung	323 000	14 887

Die verbliebenen Fälle für Menschen sind genau die Sorte, für die dieser Weg gedacht ist: Lohnverfahren, die nur über den Handelsnamen zugeordnet sind (Franchise oder Konzern?), auffällige Stundenangaben in den OSHA-Meldungen, ein einzelnes Großkraftwerk bei einer Firma ohne Stromgeschäft und Extremwerte im Branchenvergleich (DTE: 100 Mio. USD Umweltstrafen – echt oder falsch zugeordnet?).

Auch die KI darf nichts löschen. Ein automatisch entschiedener Fall kennzeichnet den Wert, mehr nicht. Einen gemeldeten Wert aus dem Bestand nehmen darf nur ein Mensch mit Namen, Datum und Begründung – die Quelle hat die Zahl veröffentlicht, unsere Software hat sie nicht zu überstimmen.

7.1 Reparatur-Kontrolle

Ursache	Fall	Beleg aus den Rohdaten	Stand heute	behaben
Null statt fehlend	KHC	EPA fuehrt 4 Anlagen, meldet 2022 keine Menge	2022 ohne Wert statt 0 t	ja
Programm misst CO2 nicht	MPC	Anlagen melden nur in SIPNOX (Waerme und NOx)	keine CO2-Menge statt 0 t	ja
Join vervielfacht	TSLA	1 Anlage, Historie SSSSSSSSSSSS, 2 Join-Zeilen	12 Quartale auf 1 Anlage statt 24	ja
Kein gerechnetes Verhaeltnis	GE	4,44 t/MWh war unsere Rate, nicht die von eGRID	keine Rate im Bestand, nur gemeldete Menge und Erzeugung	ja
Zaehler und Nenner bleiben	BRK-B	113 Kraftwerke, 83 TWh – GICS sagt Financials	82.7 TWh und 56.2 Mt gemeldet	ja
Keine Unfallrate aus ungepruefter Angabe	MCD	4 Meldungen mit im Median 50 h je Beschaeftigtem	gemeldete Stunden und Faelle statt gerechneter Rate	ja
Zuordnung ueber Namensteile	APD	0 Rohfaelle, 15 Faelle 'APDC Cleaning Services'	keine Lohnverfahren mehr zugerechnet	ja
Kein gerechneter Trend	PPL	2018 eine Anlage 5 kt, ab 2019 neun Anlagen 28 Mt	keine Trend- oder Intensitaetswerte im Bestand, Anlagenzahl steht daneben	ja
Zuordnung ohne Zeitraum	VST	Talen Energy gehoert nicht zu Vistra	2023: 86.3 Mt statt 96,8	ja
Aktiengattung doppelt	GOOG	GOOG und GOOGL teilen CIK 1652044	nur noch GOOGL im Bestand	ja
Nur Werte mit Quelle	alle	jeder Wert ist gemeldet oder eine Summe gemeldeter Werte	'gemeldet': 5874, 'aggregiert': 5551	ja

7.2 Drei Durchgänge mit dem Modell – und was sie gezeigt haben

Die Zahlen der ersten beiden Durchgänge stammen aus dem Stand vor der Reparatur, als das Modell noch alle 382 Fälle begutachtet hat.

	1: vor Reparatur	2: vor Reparatur	3: heute
begutachtete Fälle	382	382	18
Urteil fehler / plausibel / unklar	267 / 81 / 34	358 / 16 / 8	11 / 5 / 2
Widerspruch zu Regel-Fehler	38	0	0
davon automatisch freigegeben	33	0	0
an Menschen	212	246	5
Tokens	322 346	301 086	14 887

Durchgang 1 war zu nachgiebig. Die Definition lautete: „plausibel: Der Wert ist ungewöhnlich, aber durch die Belege erklärt“. Das Modell nahm sie wörtlich und schrieb bei den Nullen aus SIPNOX-Anlagen sinngemäß: 0 t CO₂ ist plausibel, weil das Programm CO₂ nicht misst. Die Ursache stimmt, das Urteil nicht – die Null bleibt als Messwert unbrauchbar. 33 echte Fehler wären ohne Mensch freigegeben worden, bei hoher Konfidenz.

Durchgang 2 schlug ins Gegenteil aus. Die präzisere Frage („Darf dieser Wert so als Messwert verrechnet werden?“) beseitigte die Freigaben, aber das Modell folgte der Regel nun fast immer: 358 von 382 Fällen hießen Fehler, darunter breite Rangbänder, die nur unsicher sind. Ein Gutachter, der die Regelmeldung im Belegpaket liest, ist eben kein unabhängiger zweiter Prüfer.

Durchgang 3 ist der eigentliche Punkt. Nicht das Modell wurde besser, sondern die Fragestellung kleiner: Was systematisch war, ist repariert; das Modell sieht nur noch, was keine Regel entscheiden kann. Es begutachtet 18 statt 382 Fälle, an Menschen gehen 5 statt 246, und der Lauf kostet 14 887 statt 322 346 Tokens.

Lehre. Die hohe Konfidenz des Modells hat den Fehler in Durchgang 1 nicht angezeigt, sondern verdeckt – genau das Muster aus der Literatur zur Überkonfidenz [9]. Gefunden hat ihn erst der Abgleich mit der Regel. Deshalb gilt weiter: Ein Widerspruch zwischen zwei Prüfern ist das wertvollste Signal für einen Menschen, und Freigaben hängen nie allein am Modell. Offen bleibt eine echte Messung der Trefferquote: Dafür braucht es eine Referenzmenge mit ebenso vielen Fehlalarmen wie echten Fehlern und ein Belegpaket ohne Regelttext.

8 Grenzen und nächste Schritte

- Reparieren heißt auch wegnehmen. Rund 1 300 Werte sind aus dem Datensatz verschwunden – Nullen, die keine Messung waren, Raten ohne Stromgeschäft, Verfahren fremder Firmen. Eine Lücke ist ehrlicher als eine falsche Zahl, aber sie bleibt eine Lücke: Firmen ohne belastbare Werte müssen als nicht bewertbar erscheinen, nicht als sauber.
- Der Zuschnitt der Aggregation bleibt unsere Entscheidung: welche Anlage zu welcher Firma gehört, mit welcher Eigentümerquote und in welchem Jahr. Das ist der einzige Schritt zwischen Quelle und Datensatz, der Urteil enthält – er steht in `resolve.py` und ist der nächste Kandidat für eine Kennung statt eines Namens (GLEIF, CC0).
- Die Regeln sind so gut wie die Mechanismen, die man kennt. Neue Fehlerarten fängt zuerst nur die Statistik – und die meldet auch echte Extreme.
- Zehn Kontrollfälle sind wenig, und sie stammen von einer Person. Sie sollten aus menschlichen Entscheidungen wachsen, mit einer zweiten Person bei strittigen Fällen.
- Die Messung der KI-Trefferquote steht damit aus: Die alten Referenzfälle prüfen jetzt die Reparatur, neue Referenzfälle entstehen erst aus dem Prüfablauf.
- Nächste Schritte in der Reihenfolge der Wirkung: die Konzernbeziehungen von GLEIF (CC0) für die Zuordnung statt Namensabgleich; eine historische Indexliste statt des heutigen Stands; Kardinalitätstests als Bibliothek statt einzelner Asserts; danach die Kalibrierung der Weiterleitungsschwelle an einer größeren Referenzmenge.

Literatur

- [1] U.S. Government Publishing Office: 40 CFR 98.2 – Who must report?, Absatz (i). <https://www.ecfr.gov/current/title-40/chapter-I/subchapter-C/part-98/subpart-A/section-98.2>
- [2] U.S. EPA, Clean Air Markets Division: CAMD’s Power Sector Emissions Data Guide, Juli 2022. <https://www.epa.gov/system/files/documents/2022-07/CAMD’s%20Power%20Sector%20Emissions%20Data%20Guide%20-%202007182022.pdf>
- [3] U.S. OSHA: Injury Tracking Application (ITA) Data Users Guide. https://www.osha.gov/sites/default/files/ITA_data_users_guide.pdf
- [4] OpenSanctions Pairs: Large-Scale Entity Matching with LLMs, arXiv:2603.11051. <https://arxiv.org/abs/2603.11051>

- [5] Science Based Targets initiative: What’s changing on the SBTi Target Dashboard; Commitment and Target Statuses, Version 2.0, August 2026. <https://sciencebasedtargets.org/blog/whats-changing-on-the-sbti-target-dashboard>
- [6] endjin: Creating Quality Gates in the Medallion Architecture with Pandera. <https://endjin.com/blog/creating-quality-gates-in-the-medallion-architecture-with-pandera>
- [7] Data Contracts and Data Quality: Enforcing Reliability in Modern Pipelines. <https://aicodeinvest.com/data-contracts-data-quality-enforcement-guide/>
- [8] GLEIF: LEI Data Terms of Use (CC0 1.0); Level 2 Data: Who Owns Whom. <https://www.gleif.org/en/meta/lei-data-terms-of-use>
- [9] Overconfidence in LLM-as-a-Judge: Diagnosis and Confidence-Driven Solution, arXiv:2508.06225. <https://arxiv.org/abs/2508.06225>
- [10] Judge, Retrieve, or Abstain: Uncertainty-Guarded LLM Judging with Provable Risk Guarantees, arXiv:2608.17994. <https://arxiv.org/abs/2608.17994>