

Prüfung: Was gemacht wurde

Vorgehen, Werkzeuge und Bedienung des Tabs „Prüfung“

ETHack 2026 · Stand 13. September 2026

Details und Quellen im Ursachenbericht [qualitaetspruefung.pdf](#)

Kurz. Der Datensatz enthielt unglaubliche Werte. Wir haben jede Auffälligkeit auf ihre Ursache zurückgeführt, daraus 382 Prüffälle mit Regeln erzeugt, jeden Fall von einem Sprachmodell mit Belegen begutachten lassen und eine feste Regel festgelegt, wann ein Mensch entscheidet. Fehlerhafte Werte bleiben im Datensatz, tragen aber einen Status und erscheinen nicht mehr in der Firmenansicht.

1 Ursachen finden

Ausgangspunkt war der Verbesserungsbericht des Teams. Jede Vermutung wurde an den Rohdaten nachgesehen und, wo es um die Bedeutung eines Feldes ging, an der Dokumentation der Quelle belegt (EPA-Meldeverordnung, CAMD-Datenleitfaden, OSHA-ITA-Leitfaden, ECHO-Feldbeschreibung, SBTi-Statusdefinitionen). Ergebnis: sieben Mechanismen, fast alle an der Nahtstelle zwischen Quelle und Pipeline – nicht in den Quellen selbst. Zwei Diagnosen des Verbesserungsberichts wurden korrigiert (CAMPD-Nullen, ECHO-Werte über 12).

2 Regeln schreiben

Aus jedem Mechanismus wurde eine Regel in `pipeline/quality.py`. Jede Regel erzeugt Fälle mit Stufe (*fehler* oder *prüfen*), Wirkung in Tonnen, Rankingrelevanz und einem Belegpaket.

Ergebnis		Anzahl
Fälle gesamt	aus 15 Regeln	382
Stufe fehler	nachweislich falsch, wird nicht verrechnet	239
Stufe prüfen	auffällig, braucht weiteren Beleg	143
betroffene Firmen		176
rankingrelevante Fälle	Firma steht im Umwelt-Ranking	106

3 KI-Gutachten

`pipeline/ai_review.py` schickt jedes Belegpaket an `gpt-5.4-mini`. Die Antwort hat eine feste Form: Urteil (*fehler*, *plausibel*, *unklar*), Ursache aus einer festen Liste, Vorschlag, Konfidenz, Bedarf an einem Menschen. Das Modell darf keine Firmenzahlen aus dem Gedächtnis ergänzen. Unsichere Antworten gehen an `gpt-5.5`. Alle Antworten liegen im Zwischenspeicher, ein zweiter Lauf ist kostenlos und liefert dasselbe.

Gemessen wird das Modell an zehn Referenzfällen, deren richtige Antwort aus den Rohdaten belegt ist: 10 von 10 Urteilen und 7 von 10 Ursachen richtig.

Was schiefging und behoben wurde. Im ersten Durchgang hielt das Modell erklärbare Fehler für „plausibel“ – 33 echte Fehler wären automatisch freigegeben worden. Die Frage wurde präzisiert, und eine feste Regel schickt jeden Widerspruch zwischen Regel und KI an einen Menschen. Im zweiten Durchgang folgt das Modell der Regel dafür fast immer. Deshalb entscheidet über Freigaben nie das Modell allein.

4 Weiterleitung

- **an Menschen:** KI unsicher auch nach Eskalation; KI widerspricht einer Fehler-Regel; KI verlangt Rohdaten- oder Dokumentenzugang; Unterdrücken oder Korrigieren bei Wirkung ab 1 Mt oder Rankingrelevanz.
- **automatisch:** alle übrigen Fälle. Der Status folgt dann der Regel; nur wenn die KI sicher „plausibel“ sagt und keine Fehler-Regel widerspricht, wird der Wert freigegeben.

Dieser Lauf: 136 automatisch, 246 an Menschen, 23 eskaliert.

5 Mensch entscheidet im Datenbrowser

1. Tab **Prüfung** öffnen, oben den eigenen Namen eintragen (bleibt im Browser gespeichert).
2. Filter steht auf *an Menschen* und *offen*. Sortiert ist nach Rankingrelevanz, dann Wirkung in Tonnen, dann Unsicherheit der KI.
3. Fall aufklappen, Regelmeldung, KI-Begründung und Belege lesen.
4. Einen Satz Begründung schreiben und einen Knopf drücken:
 - **Fehler bestätigen** – der Wert wird nicht verrechnet.
 - **Korrektur nötig** – der Wert ist falsch, Quelle oder Zuordnung muss angepasst werden; bis dahin wird er nicht verrechnet.
 - **Wert ist ok** – Fehlalarm, der Wert bleibt.
5. Die Entscheidung wird sofort auf dem Server gespeichert und lässt sich zurücknehmen. Über *Entscheidungen als CSV* lässt sie sich jederzeit herunterladen.

6 Entscheidungen zurück in den Datensatz

Befehl	Wirkung
<code>scripts/entscheidungen_holen.sh</code>	holt die Entscheidungen vom Server nach <code>data/review/entscheidungen.csv</code>
<code>python scripts/10_pruefung.py --ai</code>	Regeln und KI neu, menschliche Entscheidungen haben Vorrang
<code>python scripts/07_dataset.py</code> Web bauen und deployen	schreibt <code>quality_status</code> je Wert in den Datensatz Firmenansicht ohne Fehlerwerte, Chip „prüfen“ an fraglichen Werten

Jede Entscheidung ist ein neuer Referenzfall für die Messung der KI; wiederkehrende Entscheidungen sind Kandidaten für neue Regeln.

7 Dateien

<code>pipeline/quality.py</code>	15 Prüfregele und Belegpakete
<code>pipeline/ai_review.py</code>	KI-Gutachten, Schema, Zwischenspeicher, Weiterleitung
<code>pipeline/flag_apply.py</code>	Status je Wert im Datensatz
<code>scripts/10_pruefung.py</code>	Lauf, Referenzmessung, Berichtstabellen
<code>web/app/pruefung/</code>	Tab mit Warteschlange und Entscheidungsknöpfen
<code>web/app/api/entscheidungen/</code>	Speichern, Zurücknehmen, CSV-Export
<code>data/out/flags_gepruft.csv</code>	alle Fälle mit KI-Urteil und Weg
<code>report/qualitaetspruefung.pdf</code>	Ursachen, Belege, Verbesserungen, Literatur
