

Warum die Daten Fehler enthalten

Ursachen, Belege und ein Prüfablauf aus Regeln, KI und Mensch

ETHack 2026 – Folgebericht zum Verbesserungsbericht

12. September 2026

Zusammenfassung

Der Verbesserungsbericht hat 380 auffällige Werte beschrieben. Dieser Bericht fragt, *warum* sie entstehen, prüft jede Vermutung an den Rohdaten und an der Dokumentation der Quellen, und baut daraus einen Prüfablauf. Das Ergebnis ist unbequem und hilfreich zugleich: Die meisten Fehler sind keine Tippfehler, sondern entstehen an wenigen Stellen, an denen die Pipeline eine Quelle anders liest, als sie gemeint ist – eine Null, die „nicht gemeldet“ heißt; ein Messprogramm, das CO₂ gar nicht erfasst; eine Anlage, die beim Zusammenführen doppelt zählt; eine Tochterfirma, die zum falschen Jahr gehört. Zwei Diagnosen des Verbesserungsberichts halten der Prüfung nicht stand: Die CAMPD-Nullen sind keine Fehlsuordnungen, und die ECHO-Werte über 12 sind keine falsch gezählten Programme, sondern doppelt verbundene Zeilen. Ein neues Regelwerk findet 382 Kandidaten. Ein Sprachmodell beurteilt jeden mit einem Belegpaket; an zehn Fällen mit belegter Antwort liegt es 10 von 10 Mal richtig. Wer am Ende entscheidet, legt eine feste Regel fest und nicht das Modell.

Inhaltsverzeichnis

1	Was geprüft wurde	3
2	Warum die Fehler entstehen	3
2.1	Eine Null, die „nicht gemeldet“ heißt	3
2.2	Ein Programm, das die Größe nicht misst	4
2.3	Zusammenführen, das Zeilen vervielfacht	4
2.4	Eine Quelle, die ihre Angaben nicht prüft	4
2.5	Namen statt Kennungen	5
2.6	Zeit, die nicht mitgeführt wird	5
2.7	Definitionen, die zusammengeworfen werden	5
3	Wie man es verbessert: zuerst ohne KI	5
4	Wie man KI wirksam einbaut	6
4.1	Wo KI hilft – und wo nicht	6
4.2	Der Aufbau	6
4.3	Warum die Konfidenz des Modells nicht reicht	7
5	Wo der Mensch gebraucht wird	7

6	Ergebnisse dieses Laufs	8
6.1	Der erste Durchgang hatte einen Fehler – in der Frage, nicht im Modell	8
6.2	Referenzfälle (Durchgang 2)	9
7	Grenzen und nächste Schritte	9

1 Was geprüft wurde

Grundlage sind der gesammelte Datensatz (`dataset_long.parquet`), die Firmen-Zwischentabellen und – anders als beim Verbesserungsbericht – die Rohdaten aller Quellen im Zwischenspeicher. Jede Ursache in Abschnitt 2 ist an mindestens einem konkreten Fall in den Rohdaten nachgesehen und, wo es um die Bedeutung eines Feldes geht, an der Dokumentation der Quelle belegt.

Regel	Befund	Stufe	Fälle	Firmen	Beispiele
F01	Zwei Ticker teilen eine CIK: Konzernwerte doppelt	fehler	3	3	FOXA, GOOGL, NWSA
F02	Exakt 0 t trotz zugeordneter Anlage	fehler	83	18	AZO, BAX, CARR, CEG, CSGP, DOV
F03	0 t CO ₂ , Programm verlangt kein CO ₂	fehler	99	16	ADM, CE, CTVA, EMN, GE, HON
F04	Mehr als 12 Verstoßquartale je Anlage	fehler	2	2	NOC, TSLA
F05	Mehr als 1,3 t CO ₂ je MWh	fehler	1	1	GE
F06	Stromrate eines Nicht-Versorgers	pruefen	23	23	ABBV, ADM, BMY, BRK-B, DOW, ECL
F07	Trend oder Basisjahr durch Anlagenbasis verzerrt	fehler	7	7	CEG, CNP, DD, KKR, NEE, PPL
F08	Tochter vor oder ohne Konzernzugehörigkeit	fehler	20	5	CEG, OXY, SW, VST, XOM
F09	Unfallrate auf unplausiblen Stunden	fehler	4	4	BR, MCD, NXPI, VTR
F10	Lohnverfahren: Team-Zuordnung nicht nachvollziehbar	pruefen	35	35	AMT, AOS, APD, APO, AXP, BEN
F11	Lohnverfahren ohne Nachzahlung und Betroffene	pruefen	69	69	ACN, AVY, AZO, BAX, BDX, BLK
F12	SBTi: validiert und zurückgezogen vermischt	fehler	25	25	ADI, BXP, CLX, CRWD, F, FTNT
F13	SBTi: Zieljahr vorbei	pruefen	4	4	AMD, NRG, PYPL, SPGI
P01	Extrem im Branchenvergleich	pruefen	1	1	FSLR
P02	Rangband breiter als 70 Punkte	pruefen	6	6	AAPL, AZO, BAX, F, MDLZ, TGT

Fehler heißt: nachweislich falsch oder irreführend, nicht verrechnen. *Prüfen* heißt: auffällig, aber ohne weiteren Beleg nicht entscheidbar. 176 Firmen sind betroffen, 106 Fälle betreffen Firmen im Umwelt-Ranking.

2 Warum die Fehler entstehen

Sieben Mechanismen erklären fast alles. Keiner davon ist ein Tippfehler in einer Quelle; fast alle entstehen an der Nahtstelle zwischen dem, was eine Quelle meint, und dem, was die Pipeline daraus liest.

2.1 Eine Null, die „nicht gemeldet“ heißt

Befund. 83 Firmenjahre stehen bei exakt 0 t CO₂, obwohl der Firma Anlagen zugeordnet sind. Kraft Heinz fällt von 45 412 t (2021) auf 0 (2022), mit denselben vier Anlagen.

Mechanismus. Die EPA-Tabelle führt eine Anlage weiter in den Stammdaten, auch wenn sie keine Menge mehr meldet. Die Pipeline summiert fehlende Mengen als 0. In den Rohdaten sind es 19 155 Anlagenjahre mit 0 t; bei 17 394 davon gibt es überhaupt keine gemeldete Menge – weder direkt noch geliefert – und bei 15 733 fehlt sogar der Anlagentyp. Eine regulatorische Erklärung liefert die Aussteigeregulierung 40 CFR 98.2(i): Wer fünf Jahre unter 25 000 t oder drei Jahre unter 15 000 t liegt, darf die Meldung einstellen [1]. Die Anlage verschwindet dann nicht aus dem Register, ihre Menge schon.

Folge. Eine Null in dieser Quelle bedeutet „nicht gemessen“, fast nie „emissionsfrei“. Wer sie als Zahl verrechnet, macht Firmen sauberer und erzeugt Trends, die nur das Meldeverhalten abbilden.

2.2 Ein Programm, das die Größe nicht misst

Befund. Marathon Petroleum, Valero, ADM und Merck stehen acht Jahre lang bei 0 t CO₂ gemessenen Kraftwerks-CO₂. Der Verbesserungsbericht vermutete Fehlzusordnungen.

Mechanismus. Die Zuordnung stimmt – es sind echte Kessel und Turbinen dieser Firmen. Laut Programmfeld melden sie aber ausschließlich im Programm SIPNOX. Der Datenleitfaden der EPA nennt für SIPNOX „Heat input and NO_x emissions“, für RGGI dagegen „Heat input and CO₂ emissions“; CO₂ verlangen das Acid Rain Program, RGGI und NSPS4T [2]. Merck meldet 2,2 Millionen MWh Last bei 0 t CO₂ – die Last wird gemessen, das CO₂ nicht.

Korrektur am Verbesserungsbericht. Keine Fehlzusordnung, sondern eine fehlende Messpflicht. Die richtige Reparatur ist nicht, die Anlagen zu verwerfen, sondern CO₂-Werte nur aus Programmen zu übernehmen, die CO₂ verlangen.

2.3 Zusammenführen, das Zeilen vervielfacht

Befund. Tesla: 24 Verstoßquartale je Anlage, Northrop Grumman 13,5. In drei Jahren sind höchstens 12 möglich.

Mechanismus. Die ECHO-Historie ist eine Zeichenkette mit genau 12 Zeichen, eines je Quartal: _ beanstandungsfrei, V Verstoß, S schwerer Verstoß, U ungeklärt, Leerzeichen ohne Daten. Tesla hat eine einzige Anlage mit SSSSSSSSSSSS. Beim Verbinden mit den EPA-Anlagen über die FRS-Kennung entstehen zwei Zeilen, weil die EPA für dieselbe Anlage zwei Schreibweisen des Konzernnamens führt. Aus 12 werden 24. Zusätzlich zählt die Pipeline U als Verstoß.

Korrektur am Verbesserungsbericht. Nicht Programme statt Quartale werden gezählt, sondern dieselbe Anlage zweimal. Die Reparatur ist ein Kardinalitätstest beim Verbinden: Eine Anlage darf nach dem Join genau einmal vorkommen.

2.4 Eine Quelle, die ihre Angaben nicht prüft

Befund. McDonald's hat eine Unfallrate von 21,2 – das Dreifache des Branchen-p99. Grundlage sind vier Meldungen mit im Median 50 Arbeitsstunden je Beschäftigtem im Jahr.

Mechanismus. Die Rate ist Fälle je Stunden. Wer die Stunden falsch einträgt, erzeugt jede beliebige Rate. OSHA schreibt dazu selbst: „OSHA also does not validate the counts of workers, hours, or injury and illness counts“ und „concluding that establishments are the most dangerous or the least dangerous solely based on whether they have the highest or lowest rates from these data would be inappropriate“ [3]. Über alle Meldungen melden 9 749 Betriebe mehr als 8 760 Stunden je Beschäftigtem – mehr, als ein Jahr Stunden hat – und 18 774 weniger als 200.

2.5 Namen statt Kennungen

Befund. Die Team-Datei nennt für Air Products 212 Lohnverfahren. In den Rohdaten des Arbeitsministeriums gibt es für Air Products keinen einzigen Fall – aber 15 Fälle von „APDC Cleaning Services“.

Mechanismus. Die Lohnverfahren tragen keine Firmenkennung, nur Rechts- und Handelsnamen, oft mit Filialzusatz. Ein Abgleich über Namensbestandteile findet das Börsenkürzel „APD“ in einem fremden Firmennamen. Dasselbe Muster zeigte sich bei der eigenen Zuordnung: US Steel wurde zu Steel Dynamics, Talen Energy zu Vistra (10,5 Mt 2023, noch im Bestand). Die Forschung zu Entity Matching kommt zu einem ähnlichen Bild: Regelbasierte Verfahren neigen zum Übermatching; auf 755 540 von Fachleuten gelabelten Paaren erreichen Regeln 91,3 % F1, ein großes Sprachmodell 99,0 % [4].

2.6 Zeit, die nicht mitgeführt wird

Befund. PPL wächst angeblich um 240 % im Jahr. Constellation hat 2019 bis 2021 exakt 0 t. WestRock erscheint 2023 unter Smurfit Westrock, Pioneer unter ExxonMobil.

Mechanismus. Die Indexliste kennt nur den heutigen Stand, die Tochartabelle kennt keine Gültigkeitszeiträume. PPL hat 2018 genau eine zugeordnete Anlage mit 5 kt, ab 2019 neun Anlagen mit 28 Mt – die Zuordnung springt, nicht die Emission. Konzernumbauten (Exelon-Abspaltung 2022, WestRock-Fusion Juli 2024, Pioneer-Übernahme Mai 2024) werden rückwirkend auf alle Jahre projiziert.

2.7 Definitionen, die zusammengeworfen werden

Befund. 25 Indexfirmen sind bei SBTi „validiert“ und „Zusage zurückgezogen“ zugleich. GE hat 4,44 t CO₂ je MWh. Alphabet, Fox und News Corp stehen je zweimal im Datensatz.

Mechanismus. SBTi führt Status je Zieltyp; „Commitment removed“ heißt, dass ein Ziel nicht binnen 24 Monaten eingereicht wurde [5]. Ein gesetztes Nahziel und eine zurückgezogene Netto-null-Zusage sind kein Widerspruch – die Kennzahl wirft beides zusammen. Die Stromrate eines Heizkraftwerks ist keine Aussage über den Konzern. Und Aktiengattungen mit gemeinsamer CIK sind ein Emittent, nicht zwei.

Mechanismus	Wo es auftritt	Gegenmittel
Null heißt nicht gemeldet	EPA GHGRP	fehlend statt 0; Off-Ramp als eigener Status
Programm misst Größe nicht	CAMPD	CO ₂ nur aus ARP, RGGI, NSPS4T
Join vervielfacht	ECHO ↔ GHGRP	Kardinalitätstest nach jedem Join
Quelle prüft nicht	OSHA ITA	Nenner-Plausibilität je Meldung vor der Aggregation
Namen statt Kennungen	WHD, GHGRP, CAMPD	CIK, LEI (GLEIF, CC0), EIA-860; KI-Gutachten für Grenzfälle
Zeit nicht mitgeführt	Tochartabelle, Indexliste	Gültigkeit von–bis; historische Indexliste
Definitionen vermischt	SBTi, eGRID, CIK	Status je Zieltyp; Kennzahl nur für passende Branche; CIK-Deduplizierung

3 Wie man es verbessert: zuerst ohne KI

KI ist nicht der erste Hebel. Die meisten Fehler oben lassen sich mit Regeln verhindern, die schneller, billiger und reproduzierbar sind. Die Reihenfolge folgt der verbreiteten Praxis von Datenverträgen:

Prüfungen an jeder Stelle, an der Daten ihre Form ändern, auffällige Zeilen in Quarantäne statt stiller Löschung [6, 7].

1. **Fehlend ist nicht Null.** Wo eine Quelle keine Menge meldet, bleibt der Wert leer. Das betrifft die Summierung der EPA-Mengen und jede Aggregation danach.
2. **Messpflicht als Datenfeld.** Das Programmfeld von CAMPD mitführen und CO₂ nur übernehmen, wo ein Programm es verlangt.
3. **Kardinalitätstests.** Nach jedem Join prüfen, dass Schlüssel nicht vervielfacht werden. Ein einziges Assert hätte die ECHO-Werte über 12 verhindert.
4. **Nenner vor dem Zähler prüfen.** Unfallraten nur aus Meldungen mit 500 bis 3 500 Stunden je Beschäftigtem; unplausible Meldungen in Quarantäne.
5. **Kennungen vor Namen.** CIK für SEC, FRS für EPA, ISIN für SBTi, LEI mit den Konzernbeziehungen von GLEIF – diese stehen unter CC0 [8] und beantworten „wem gehört wer“ ohne Namensabgleich.
6. **Gültigkeitszeiträume.** Jede Zuordnung in der Tochtertabelle bekommt `gueltig_von` und `gueltig_bis`; die Indexliste wird historisch geführt.
7. **Harte Grenzen als Export-Asserts.** $ECHO \leq 12$, $eGRID \leq 1,3 \text{ t CO}_2/\text{MWh}$, keine CIK doppelt, $|\text{Trend}| < 1$. Der Lauf bricht bei Verletzung ab.
8. **Flags reisen mit.** Ein beanstandeter Wert wird nicht gelöscht, sondern trägt `quality_status`, Regel und Begründung bis in die Oberfläche. Das ist inzwischen umgesetzt.

4 Wie man KI wirksam einbaut

4.1 Wo KI hilft – und wo nicht

Regeln finden Kandidaten zuverlässig, können aber den Einzelfall nicht erklären. Genau dort liegt die Stärke eines Sprachmodells: aus einem Bündel von Belegen die wahrscheinlichste Ursache benennen. Ist „APDC Cleaning Services“ Air Products? Ist eine Stromrate bei Berkshire Hathaway ein Fehler oder echte Versorgertätigkeit? Ist ein Sprung von 5 kt auf 28 Mt Klimaschutz, ein Zukauf oder eine Lücke in der Zuordnung?

Nicht geeignet ist ein Modell dafür, fehlende Zahlen zu liefern, Konzernbeziehungen aus dem Gedächtnis zu behaupten oder allein über Werte zu entscheiden, von denen ein Ranking abhängt.

4.2 Der Aufbau

1. **Regeln setzen die Schwere.** Das Modell kann einer Regel widersprechen, aber eine Regel-Stufe nicht selbst ändern.
2. **Belegpaket statt Frage.** Jeder Fall geht mit Wert, Zeitreihe, Branchenvergleich und Rohdaten-Auszug an das Modell. Die Anweisung verbietet, Firmenzahlen aus eigenem Wissen zu ergänzen, und verlangt, allgemeines Wissen zu kennzeichnen.
3. **Feste Antwortform.** Ein JSON-Schema erzwingt Urteil (fehler, plausibel, unklar), eine Ursache aus einer festen Liste, Handlungsvorschlag, Konfidenz und die Frage, ob ein Mensch nötig ist. „Unklar“ ist ausdrücklich eine gute Antwort.
4. **Weiterleitung durch eine Regel, nicht durch das Modell.** Unsichere Fälle (Konfidenz unter 0,6 oder „unklar“) gehen an ein stärkeres Modell; bleiben sie unsicher, an einen Menschen.

Korrekturen mit großer Wirkung – ab einer Million Tonnen oder mit Einfluss auf das Ranking – gehen immer an einen Menschen.

5. **Zwischenspeicher.** Gleicher Fall, gleiche Anweisung, gleiches Modell ergibt dieselbe gespeicherte Antwort. Das macht den Lauf reproduzierbar und einen zweiten Lauf kostenlos.
6. **Messung an belegten Fällen.** Ein Modellurteil ist nur so viel wert wie seine gemessene Trefferquote. Deshalb gibt es eine Referenzmenge mit Fällen, deren Antwort aus den Rohdaten bekannt ist.

4.3 Warum die Konfidenz des Modells nicht reicht

Sprachmodelle als Gutachter sind systematisch zu sicher. Eine Untersuchung an 14 Modellen fand etwa für GPT-4o eine Genauigkeit von 49,7 % bei einem Kalibrierungsfehler von 39,3 % – die Antworten häufen sich bei 90 bis 100 % Konfidenz, die Trefferquote liegt weit darunter [9]. Zwei Gegenmittel sind belegt: mehrere Urteile zusammenführen, was Genauigkeit und Kalibrierung verbessert, und Schwellen nicht setzen, sondern an gelabelten Fällen kalibrieren. Ein aktueller Ansatz legt die Schwelle so fest, dass die Fehlerrate unter den angenommenen Urteilen mit hoher Wahrscheinlichkeit unter einer Vorgabe bleibt, holt bei Unsicherheit zusätzliche Belege und gibt sonst an Menschen ab [10].

Für dieses Projekt heißt das: Die Schwelle 0,6 ist ein Startwert, keine Kalibrierung. Sie wird erst belastbar, wenn die Referenzmenge wächst – idealerweise aus den Entscheidungen, die Menschen im Prüfablauf ohnehin treffen.

5 Wo der Mensch gebraucht wird

Ein Mensch ist teuer. Sein Einsatz lohnt sich dort, wo weder Regel noch Modell die Frage aus den vorhandenen Belegen beantworten können, oder wo ein Fehler viel kostet.

Grenzfall	Warum Regel und KI nicht reichen	Was der Mensch braucht
Stichtag eines Konzernumbaus	Das Modell kennt Übernahmen, aber nicht verlässlich das Vollzugsdatum	Pressemitteilung, 8-K-Meldung
Franchise oder eigener Betrieb	Aus dem Handelsnamen nicht entscheidbar	Franchise-Offenlegung (FDD), Adresse
Echter Extremwert oder Fehler	Vistra kann real kohlelastig sein – oder falsch zugeordnet	Anlagenliste, Geschäftsbericht
Regel und KI widersprechen sich	Einer von beiden irrt; das Muster ist lehrreich	beide Begründungen nebeneinander
Korrektur mit großer Wirkung	ab 1 Mt oder mit Einfluss auf das Ranking	Rohdaten-Auszug, Vorher-Nachher
Neue Quellendefinitionen	SBTi führt seit September 2026 neue Status ein	Definitionsdocument der Quelle
Lizenzfragen	Rechtliche Einordnung, nicht technische	Nutzungsbedingungen

Der Ablauf. Eine Entscheidung ist eine Zeile in `data/review/entscheidungen.csv` mit Flag, Entscheidung, Name, Datum und einem Satz Begründung. Beim nächsten Lauf hat sie Vorrang vor Regel und KI und fließt mit Namen in den Datensatz. Die Prüfliste in der Oberfläche sortiert nach Wirkung: rankingrelevant zuerst, dann nach Tonnen, dann nach Unsicherheit des Modells.

Der wichtigste Effekt ist der Rückfluss. Jede menschliche Entscheidung ist ein neuer Referenzfall für die Messung der KI – und jede wiederkehrende Entscheidung ein Kandidat für eine neue Regel. So wird der teure Schritt mit der Zeit seltener, ohne dass man ihm blind vertraut.

6 Ergebnisse dieses Laufs

Kandidaten aus den Regeln	382
davon Stufe Fehler	239
davon Stufe Prüfen	143
Modell (erster Durchgang)	gpt-5.4-mini
Modell (Eskalation)	gpt-5.5
KI-Urteil fehler / plausibel / unklar	358 / 16 / 8
KI bestätigt Regel-Fehler	239
KI hält Regel-Fehler für plausibel	0
eskaliert	23
automatisch entschieden	136
an Menschen weitergeleitet	246
Tokens insgesamt	301 086

6.1 Der erste Durchgang hatte einen Fehler – in der Frage, nicht im Modell

Im ersten Durchgang lautete die Definition: „plausibel: Der Wert ist ungewöhnlich, aber durch die Belege erklärt“. Das Modell hat sie wörtlich genommen. Bei den Nullen aus SIPNOX-Anlagen schrieb es sinngemäß: 0 t CO₂ ist plausibel, weil das Programm CO₂ nicht misst. Die Ursache stimmt, das Urteil ist trotzdem falsch – die Null bleibt als Messwert unbrauchbar. So entstanden 38 Widersprüche zu Regel-Fehlern, und 33 davon wären ohne Mensch freigegeben worden, weil das Modell sich sicher war.

Zwei Änderungen: Die Frage heißt jetzt ausdrücklich „Darf dieser Wert so als Messwert verrechnet werden?“, mit dem Hinweis, dass eine erklärte Ursache einen Wert nicht gültig macht. Und eine feste Regel: Widerspricht die KI einer Regel, die „Fehler“ sagt, entscheidet immer ein Mensch. Im zweiten Durchgang bleiben 0 Widersprüche, automatisch freigegeben werden 0.

	Durchgang 1	Durchgang 2
KI-Urteil fehler / plausibel / unklar	267 / 81 / 34	358 / 16 / 8
Widerspruch zu Regel-Fehler	38	0
davon automatisch freigegeben	33	0
Referenz: Urteil richtig	9 von 10	10 von 10
Referenz: Ursache richtig	7 von 10	7 von 10

Der zweite Durchgang schlägt ins Gegenteil aus. Die präzisere Frage hat die Freigaben beseitigt, aber das Modell folgt der Regel jetzt fast immer: 358 von 382 Fällen nennt es Fehler. Darunter sind Fälle, die keine Fehler sind – ein breites Rangband ist eine Unsicherheit, kein falscher Wert, und ein Lohnverfahren ohne Nachzahlung kann echt sein. Von 81 Fällen, die im ersten Durchgang „plausibel“ hießen, sind 64 jetzt „Fehler“. Die Referenzmenge zeigt das nicht, weil sie neun echte Fehler und nur einen echten Grenzfall enthält. Der Widerspruch zwischen Regel und KI fällt damit als Signal fast weg.

Lehre. Die hohe Konfidenz des Modells hat den Fehler nicht angezeigt, sondern verdeckt – genau das Muster aus der Literatur zur Überkonfidenz. Gefunden hat ihn erst der Abgleich mit der Regel. Deshalb gilt: Ein Widerspruch zwischen zwei unabhängigen Prüfern ist das wertvollste Signal für einen Menschen, und Freigaben dürfen nie allein am Modell hängen. Und: Das Belegpaket enthält die Regelmeldung. Ein Gutachter, der das Urteil der Regel sieht, ist nicht mehr unabhängig. Der nächste Schritt ist ein blinder Durchgang ohne Regeltext, dazu eine Referenzmenge mit ebenso vielen Fehlalarmen wie echten Fehlern.

6.2 Referenzfälle (Durchgang 2)

Firma	Beleg	erwartet KI-Urteil		KI-Ursache	Konf.	Weg
GOOGL	GOOG und GOOGL teilen CIK 1652044	fehler	fehler (ja)	doppelzaehlung (ja)	0.92	automatisch
KHC	4 Anlagen gemeldet, keine Emissionszeile mit Menge	fehler	fehler (ja)	null_statt_fehlend (ja)	0.93	mensch
MPC	Programm SIPNOX, CO2 nicht meldepflichtig	fehler	fehler (ja)	programm_misst_groesse_nicht (ja)	0.93	automatisch
TSLA	1 Anlage, Historie SSSSSSSSSSSS, 2 Join-Zeilen durch 2 Namensschreibweisen	fehler	fehler (ja)	doppelzaehlung (ja)	0.98	mensch
BRK-B	Berkshire Hathaway Energy betreibt echte Versorger; nur GICS sagt Financials	plausibel	plausibel (ja)	branchenstruktur_real (ja)	0.78	automatisch
GE	4,44 t/MWh, ein Heizkraftwerk, physikalisch unmöglich als Stromrate	fehler	fehler (ja)	programm_misst_groesse_nicht (nein)	0.89	mensch
PPL	2018 1 Anlage 5 kt, ab 2019 9 Anlagen 28 Mt	fehler	fehler (ja)	meldefehler_quelle (nein)	0.87	mensch
VST	Talen Energy ist nicht Teil von Vistra	fehler	fehler (ja)	zuordnung_falsch (ja)	0.95	mensch
MCD	4 Meldungen, Median 50 h je Beschäftigtem	fehler	fehler (ja)	definition_oder_einheit (nein)	0.94	mensch
APD	0 Rohfälle für Air Products, 15 Fälle 'APDC Cleaning Services'	fehler	fehler (ja)	zuordnung_falsch (ja)	0.96	automatisch

Zehn Fälle sind zu wenig, um eine Schwelle zu kalibrieren. Sie reichen, um grobe Fehlanreize zu sehen – etwa ob das Modell reflexhaft der Regel folgt, ob es „unklar“ nutzt, und ob es die richtige Ursache benennt, nicht nur das richtige Urteil.

7 Grenzen und nächste Schritte

- Die Regeln sind so gut wie die Mechanismen, die man kennt. Neue Fehlerarten fängt zuerst nur die Statistik – und die meldet auch echte Extreme.
- Die Referenzmenge ist klein und von einer Person zusammengestellt. Sie sollte aus menschlichen Entscheidungen wachsen, mit einer zweiten Person bei strittigen Fällen.
- Das Modell sieht nur die Belege im Paket. Wo ein Rohdaten-Auszug fehlt, kann es nur „unklar“ sagen – das ist gewollt.
- Nächste Schritte in der Reihenfolge der Wirkung: fehlend statt Null in der EPA-Summierung, Programmfilter bei CAMPD, Kardinalitätstest bei ECHO, Nenner-Filter bei OSHA, Gültigkeitszeiträume und GLEIF-Beziehungen für die Zuordnung, danach die Kalibrierung der Weiterleitungsschwelle an einer größeren Referenzmenge.

Literatur

- [1] U.S. Government Publishing Office: 40 CFR 98.2 – Who must report?, Absatz (i). <https://www.ecfr.gov/current/title-40/chapter-I/subchapter-C/part-98/subpart-A/section-98.2>

- [2] U.S. EPA, Clean Air Markets Division: CAMD’s Power Sector Emissions Data Guide, Juli 2022. <https://www.epa.gov/system/files/documents/2022-07/CAMD's%20Power%20Sector%20Emissions%20Data%20Guide%20-%2007182022.pdf>
- [3] U.S. OSHA: Injury Tracking Application (ITA) Data Users Guide. https://www.osha.gov/sites/default/files/ITA_data_users_guide.pdf
- [4] OpenSanctions Pairs: Large-Scale Entity Matching with LLMs, arXiv:2603.11051. <https://arxiv.org/abs/2603.11051>
- [5] Science Based Targets initiative: What’s changing on the SBTi Target Dashboard; Commitment and Target Statuses, Version 2.0, August 2026. <https://sciencebasedtargets.org/blog/whats-changing-on-the-sbti-target-dashboard>
- [6] endjin: Creating Quality Gates in the Medallion Architecture with Pandera. <https://endjin.com/blog/creating-quality-gates-in-the-medallion-architecture-with-pandera>
- [7] Data Contracts and Data Quality: Enforcing Reliability in Modern Pipelines. <https://aicodeinvest.com/data-contracts-data-quality-enforcement-guide/>
- [8] GLEIF: LEI Data Terms of Use (CC0 1.0); Level 2 Data: Who Owns Whom. <https://www.gleif.org/en/meta/lei-data-terms-of-use>
- [9] Overconfidence in LLM-as-a-Judge: Diagnosis and Confidence-Driven Solution, arXiv:2508.06225. <https://arxiv.org/abs/2508.06225>
- [10] Judge, Retrieve, or Abstain: Uncertainty-Guarded LLM Judging with Provable Risk Guarantees, arXiv:2608.17994. <https://arxiv.org/abs/2608.17994>